



Universidade Federal do ABC
Centro de Matemática, Computação e Cognição
Programa de Pós-Graduação em Neurociência e Cognição

Efeito da Neuromodulação Não Invasiva na Sincronicidade Cérebro-Corpo em Atletas do Basquetebol

Danilo Cavalcante Brambila de Barros

Número de Ordem : XXXX
São Bernardo do Campo - SP, 2025

Danilo Cavalcante Brambila de Barros

Efeito da Neuromodulação Não Invasiva na Sincronicidade Cérebro-Corpo em Atletas do Basquetebol

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Neurociência e Cognição, como parte dos requisitos necessários para a obtenção do Título de Mestre em Neurociência e Cognição.

Universidade Federal do ABC – UFABC
Centro de Matemática, Computação e Cognição
Programa de Pós-Graduação em Neurociência e Cognição

Orientador: Prof. Dr. Alexandre Hideki Okano
Coorientador: Prof. Dr. Edgard Morya

São Bernardo do Campo - SP
2025

Danilo Cavalcante Brambila de Barros

Efeito da Neuromodulação Não Invasiva na Sincronicidade Cérebro-Corpo
em Atletas do Basquetebol/

Danilo Cavalcante Brambila de Barros. – São Bernardo do Campo - SP, 2025.

83 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Dr. Alexandre Hideki Okano

Dissertação (Mestrado) – Universidade Federal do ABC – UFABC

Centro de Matemática, Computação e Cognição

Programa de Pós-Graduação em Neurociência e Cognição, 2025.

1. Neuromodulação. 2. Sincronização Cérebro-Corpo. 3. Basquetebol.

I. Orientador. II. Universidade Federal do ABC. III. Programa de Pós-Graduação
em Neurociência e Cognição. IV. Título.

CDU 02:141:005.7

Danilo Cavalcante Brambila de Barros

Efeito da Neuromodulação Não Invasiva na Sincronicidade Cérebro-Corpo em Atletas do Basquetebol

Dissertação de Mestrado apresentada ao Programa de Pós-Graduação em Neurociência e Cognição, como parte dos requisitos necessários para a obtenção do Título de Mestre em Neurociência e Cognição.

Trabalho aprovado. São Bernardo do Campo - SP, 01 de março de 2025:

Prof. Dr. Alexandre Hideki Okano
Orientador

Prof. Dr. Edgard Morya
Co-Orientador

Professor
Convidado 1

Professor
Convidado 2

Professor
Convidado 3

São Bernardo do Campo - SP
2025

Dedico este trabalho a todos os estudantes e pesquisadores que, movidos pela curiosidade e pela paixão pelo conhecimento, buscam entender os mistérios do cérebro e do corpo humano. Que esta pesquisa possa servir como inspiração para novas descobertas e avanços na ciência.

Agradecimentos

Agradeço à minha **família**, pelo amor e apoio incondicional, fundamentais para eu chegar até aqui. Ao meu **orientador** e **coorientador**, pela oportunidade de explorar novas ideias, pelo incentivo contínuo e por ser fonte de inspiração e aprendizado ao longo desta caminhada. Aos **colegas de laboratório**, pela convivência, troca de ideias e colaboração, que tornaram essa jornada mais enriquecedora e inspiradora. Aos **professores e colaboradores** que, de alguma forma, contribuíram para a realização deste estudo.

“Se o cérebro humano fosse simples o suficiente para que pudéssemos entendê-lo, seríamos tão simples que não conseguiríamos entendê-lo.”
(Emerson Pugh)

Resumo

Segundo a ABNT, o resumo deve ressaltar o objetivo, o método, os resultados e as conclusões do documento. A ordem e a extensão destes itens dependem do tipo de resumo (informativo ou indicativo) e do tratamento que cada item recebe no documento original. O resumo deve ser precedido da referência do documento, com exceção do resumo inserido no próprio documento. Umas 10 linhas (...) As palavras-chave devem figurar logo abaixo do resumo, antecedidas da expressão Palavras-chave:, separadas entre si por ponto e finalizadas também por ponto.

Palavras-chaves: latex. abntex. editoração de texto.

Abstract

This is the english abstract.

Keywords: latex, abntex, text editoration.

Lista de ilustrações

Lista de tabelas

Lista de abreviaturas e siglas

EEG	Eletroencefalograma
EMG	Eletromiografia
PLV	Phase Locking Value
ECG	Eletrocardiograma
HD-tDCS	Estimulação Transcraniana por Corrente Contínua de Alta Definição
IQR	Intervalo Interquartil

Lista de símbolos

- α Banda de frequênciα Alpha (8-13 Hz)
- β Banda de frequênciα Beta (13-30 Hz)
- γ Banda de frequênciα Gamma (30-60 Hz)
- θ Banda Theta (4-8 Hz)
- δ Banda Delta (0.5-4 Hz)

Sumário

Parte I

Introdução e Fundamentação Teórica

1 Introdução

A interação entre o cérebro e o corpo é fundamental para o desempenho atlético, e a neurociência tem avançado significativamente na compreensão dessa relação. No contexto esportivo, o conceito de sincronização cérebro-corpo, ou sistema dinâmico cérebro-corpo (BBDS, do inglês Body Brain Dynamic System), emerge como um elemento-chave na execução de tarefas motoras complexas. Esse sistema refere-se à integração dinâmica entre atividades cerebrais e fisiológicas que ocorrem durante a execução de movimentos, como no caso do arremesso livre no basquetebol.

Com o advento de tecnologias como a eletroencefalografia (EEG), tornou-se possível investigar detalhadamente as oscilações cerebrais que ocorrem durante diferentes atividades. Essas oscilações, embora sua origem e significado ainda sejam amplamente debatidos, têm mostrado potencial para se sincronizar com ritmos corporais, como os da frequência cardíaca e respiratória, formando um padrão rítmico integrado que pode influenciar diretamente o desempenho atlético (????).

A neuromodulação, especialmente a estimulação transcraniana por corrente contínua (tDCS), tem demonstrado potencial para alterar a excitabilidade cortical e, consequentemente, modular esse sistema dinâmico (????). No entanto, ainda são escassos os estudos que exploram esses efeitos no contexto esportivo, particularmente em atletas de basquetebol.

Este projeto visa explorar e compreender como a tDCS, em sua modalidade de alta definição (HD-tDCS), pode impactar a sincronização cérebro-corpo em atletas de basquetebol, especificamente durante a execução de arremessos livres. A pesquisa busca evidenciar a existência e o papel do BBDS na modulação do desempenho esportivo, fornecendo insights sobre a potencial aplicação dessa técnica no aprimoramento de habilidades motoras e cognitivas no esporte.

1.1 Sincronicidade cérebro-corpo no esporte

A sincronicidade entre as oscilações cerebrais e as frequências corporais é um fenômeno que pode otimizar a execução de tarefas motoras complexas, como o arremesso livre no basquetebol. Utilizando o EEG para captar as oscilações cerebrais e correlacionando-as com sinais fisiológicos de frequência cardíaca e respiratória, este projeto investiga como essas interações ocorrem e de que forma são moduladas através da tDCS.

Os seres humanos ajustam naturalmente seu ritmo respiratório a ritmos musicais, atuando como um marcapasso biológico. Esse alinhamento pode ser ainda mais acentuado

durante atividades rítmicas, como o simples ato de bater os dedos no ritmo da música (??). A pesquisa de Haas e colegas demonstra que esse tipo de sincronização, ou entrainment, é mais provável de ocorrer quando o ritmo musical é claro e o indivíduo está envolvidoativamente, como no caso do tapping. Além disso, estados psicofísicos como ansiedade, depressão e estresse, bem como o controle consciente da respiração, podem influenciar tanto a frequência cardíaca quanto a atividade cerebral (??).

Considerando a influência dos ritmos corporais na atividade cerebral, estratégias de modulação dessas frequências podem ser desenvolvidas e testadas para avaliar seu impacto no desempenho em tarefas cognitivas e motoras críticas, como o arremesso livre no basquetebol. Essa tarefa exige um alto grau de concentração, percepção espacial, controle de força e precisão de movimento, fatores que podem ser potencialmente aprimorados pela sincronicidade entre os ritmos cerebrais e corporais. Ao explorar a modulação dessas sincronicidades, espera-se identificar intervenções que possam otimizar o desempenho atlético, fornecendo uma base para aprimorar o treinamento e a preparação dos atletas em situações de alta pressão.

1.2 Neuromodulação no esporte e modulação da função cerebral

A estimulação transcraniana por corrente contínua (tDCS) tem se mostrado uma ferramenta promissora para modular a excitabilidade cortical e a função cerebral em áreas específicas, o que pode influenciar o desempenho em tarefas motoras. Estudos têm demonstrado que a tDCS pode aumentar a excitabilidade do córtex motor, modular a percepção de esforço e melhorar o desempenho em exercícios físicos, destacando seu potencial tanto em contextos clínicos quanto esportivos (????).

Polanía et al. (??) demonstraram que a tDCS anódica aplicada sobre o córtex motor primário (M1) aumenta a conectividade funcional entre M1 e o tálamo ipsilateral, além de fortalecer a conexão entre o núcleo caudado e áreas associativas corticais, indicando uma modulação do circuito motor córtico-estriado-talâmico. Stagg e Nitsche (??) acrescentam que os efeitos da tDCS, particularmente após a estimulação, estão intimamente ligados à modulação sináptica, sugerindo que a tDCS pode influenciar a plasticidade cortical ao interagir com sinapses dependentes de receptores NMDA.

Estudos anteriores demonstraram que a tDCS pode melhorar o desempenho esportivo, aumentando a excitabilidade cortical e a conectividade funcional entre diferentes regiões cerebrais (??????). Além disso, a aplicação da tDCS, especificamente sobre o córtex pré-frontal dorsolateral esquerdo, mostrou efeitos positivos em medidas subjetivas de bem-estar, percepção de recuperação e controle autonômico em atletas de elite após competições oficiais (????). Esses achados sugerem que a tDCS pode ser uma estratégia promissora para otimizar a recuperação pós-exercício e melhorar a preparação psicológica

e fisiológica dos atletas para competições subsequentes.

No entanto, ainda há muito a ser explorado sobre como diferentes configurações de eletrodos na estimulação transcraniana, como investigado por Datta et al. (??), podem influenciar a modulação cortical e, por conseguinte, os efeitos neurológicos em contextos como o repouso e o esforço físico em atletas de basquetebol.

Este projeto explorará especificamente o efeito da tDCS catódica de alta definição (HD-tDCS) no córtex pré-frontal dorsolateral (CPFDL) e como essa modulação afeta a sincronicidade entre as atividades cerebrais e corporais durante o arremesso livre.

1.3 Medidas neurofisiológicas

Para entender a complexa interação entre o cérebro e o corpo durante atividades esportivas, é fundamental integrar diversas técnicas de medida. A eletroencefalografia (EEG) fornece dados sobre a atividade elétrica cerebral, enquanto a eletromiografia (EMG) e o eletrocardiograma (ECG) capturam informações sobre a atividade muscular e cardíaca, respectivamente. Essas técnicas permitem a observação de oscilações em diferentes frequências, que podem se sincronizar de maneira complexa, um fenômeno conhecido como acoplamento de frequências cruzadas (cross-frequency coupling), essencial para compreender como os ritmos corporais e cerebrais influenciam o desempenho (??).

Moscaleski et al. (??) destacam que "as ativações cerebrais diferenciadas em atletas de alta performance suportam mecanismos neurais relevantes para o desempenho esportivo. A preparação para a ação motora envolve regiões corticais e subcorticais que podem ser moduladas de forma não invasiva por estimulação de corrente elétrica". O uso do EEG para examinar a atividade elétrica cerebral proporciona insights valiosos sobre o desempenho atlético e pode ajudar a identificar perfis específicos de EEG associados a desempenhos de alto nível.

Este estudo investiga o efeito da estimulação transcraniana por corrente contínua de alta definição (HD-tDCS) na atividade elétrica do cérebro em jogadoras profissionais de basquetebol durante o arremesso livre, explorando a relação entre os biomarcadores espectrais do EEG e a performance motora. Além disso, este estudo explora a interação entre os dados de EEG, EMG e ECG, com foco nas sincronicidades entre as bandas de frequência durante a preparação para o arremesso. Investigar esses fenômenos pode fornecer uma compreensão mais profunda sobre a integração cérebro-corpo, informando estratégias para melhorar o desempenho atlético e potencialmente beneficiando áreas como reabilitação e treinamento cognitivo.

Parte II

Objetivos e Hipóteses

2 Objetivos

O presente projeto tem como objetivo principal testar o efeito da HD-tDCS na modulação (e direção) da sincronicidade de canais de EEG e ECG utilizando as métricas de sincronicidade PLI e CF-PLM.

3 Hipóteses

A hipótese central do estudo é que a HD-tDCS modula significativamente a sincronicidade entre canais de EEG e ECG em repouso.

Parte III

Metodologia e Processamento

4 Metodologia

Este projeto utiliza dados previamente coletados pelo laboratório ao qual faço parte, envolvendo medidas de eletroencefalograma (EEG) e eletromiografia (EMG) de atletas profissionais de basquetebol feminino. O objetivo central deste estudo é investigar a sincronicidade cérebro-corpo e avaliar o impacto da estimulação transcraniana por corrente contínua de alta definição (HD-tDCS) no desempenho atlético durante arremessos de lance livre.

4.1 Participantes e Coleta de Dados

O estudo foi aprovado pelo Comitê de Ética em Pesquisa da UFABC (protocolo: 08070819.1.0000.5594) e conduzido em conformidade com os princípios éticos estabelecidos pela Declaração de Helsinque para experimentos envolvendo seres humanos. Todas as participantes assinaram o Termo de Consentimento Livre e Esclarecido (TCLE) antes de iniciarem sua participação.

As participantes eram consideradas atletas de elite, com um regime de treinamento superior a 10 horas semanais, e foram selecionadas com base em critérios rigorosos:

- Participação regular no programa de treinamento da equipe;
- Ausência de doenças ou lesões que pudessem interferir na execução do protocolo;
- Assinatura do Termo de Consentimento Livre e Esclarecido (TCLE).

A amostra foi caracterizada por meio da mensuração de massa corporal, estatura e coleta de informações detalhadas, como nome, data de nascimento, categoria, experiência esportiva, posição no time, fase da temporada, membro dominante e estilo de arremesso. Contudo, devido a problemas técnicos durante a coleta de dados, apenas os dados de 7 atletas foram utilizados nas análises (??).

Embora o tamanho reduzido da amostra possa ser considerado uma limitação, ele é uma característica comum em estudos que envolvem populações específicas e de difícil acesso, como atletas de elite. Estudos prévios, como o de Boukrina et al. (??), destacam que, em situações em que o aumento do tamanho da amostra não é viável, estratégias como a homogeneidade da amostra e análises que considerem a variabilidade individual podem proporcionar resultados robustos e significativos.

4.2 Delineamento Experimental

O delineamento experimental seguiu um modelo randomizado, cruzado e duplo-cego, amplamente utilizado em estudos de neurociência aplicada e psicofisiologia para minimizar viés e garantir a validade dos resultados. Esse modelo permitiu que todas as participantes fossem expostas tanto à condição de estimulação catódica (HD-tDCS) quanto à condição sham (simulada), aumentando a robustez das comparações intraindividuais.

Antes das sessões experimentais, foi realizada uma sessão de familiarização, na qual as participantes receberam explicações sobre os objetivos, procedimentos, riscos e benefícios do estudo, além de um período de adaptação ao protocolo experimental. Essa familiarização assegurou que todas estivessem confortáveis com os procedimentos e equipamentos utilizados.

As sessões experimentais ocorreram entre janeiro e fevereiro de 2020, com a seguinte estrutura:

- **Sessão 1:** Familiarização com dispositivos e procedimentos do estudo.
- **Sessões 2 e 3:** Protocolo experimental com 200 arremessos por sessão, totalizando 400 arremessos por atleta.

As sessões foram realizadas no mesmo local e horário do treinamento habitual das atletas, garantindo a padronização das condições ambientais. A ordem das condições experimentais foi atribuída de maneira aleatória para cada participante, conforme o modelo cruzado.

4.3 Questionários e Escalas

Além das medidas neurofisiológicas, foram aplicados questionários para avaliar aspectos subjetivos relacionados ao desempenho das atletas. Entre os instrumentos utilizados, destacam-se:

- **Escala de Qualidade Total de Recuperação (TQR):** avalia o estado geral de recuperação física e mental, fornecendo insights sobre como as participantes se sentem prontas para enfrentar novas atividades físicas após as sessões experimentais;
- **Escala de Percepção Subjetiva de Esforço (PSE):** mede o esforço percebido pelas participantes ao final de cada sessão experimental, permitindo relacionar o desempenho físico ao nível de fadiga subjetiva;

- **Sport Competition Anxiety Test (SCAT)**: identifica os níveis de ansiedade competitiva das participantes, avaliando como essa variável psicológica pode influenciar a execução das tarefas motoras propostas;
- **Questionário de Motivação Relacionado ao Exercício**: investiga os fatores motivacionais das participantes durante o experimento, analisando seu impacto no engajamento e na qualidade do desempenho.

Esses instrumentos permitiram uma análise detalhada de variáveis psicológicas complementares às medidas fisiológicas coletadas, contribuindo para uma visão integrada da sincronicidade cérebro-corpo no desempenho esportivo.

4.4 Estimulação Transcraniana por Corrente Contínua de Alta Definição (HD-tDCS)

A HD-tDCS foi realizada com um estimulador digital MxN da Soterix Medical, utilizando eletrodos Ag/AgCl posicionados em uma touca de EEG. O posicionamento dos eletrodos seguiu um protocolo padronizado baseado em modelagem computacional, garantindo precisão e focalidade na estimulação (??).

Foram aplicadas duas condições experimentais: estimulação catódica (ativa) e sham (simulada), com as participantes expostas a ambas em sessões diferentes, de forma cruzada e randomizada. A calibração dos equipamentos foi realizada antes de cada sessão para assegurar a qualidade e a confiabilidade dos dados registrados.

4.4.1 Pré-processamento de Dados

Os sinais de EEG e EMG foram submetidos a etapas de pré-processamento, como filtragem de ruídos e segmentação temporal, para garantir qualidade e consistência nos dados analisados. Detalhes específicos sobre essas etapas estão descritos no Capítulo 5.

4.4.2 Sincronização de Sinais

Os sinais de EEG e ECG foram alinhados temporalmente para permitir análises integradas, ajustando diferenças nos tempos de início das gravações. Este processo assegurou a compatibilidade entre os dados das diferentes modalidades. Os procedimentos detalhados encontram-se no Capítulo 5.

4.4.3 Cálculo de Sincronização Funcional

A conectividade funcional foi avaliada por meio do Phase Lag Index (PLI) para pares EEG-EEG e Cross-Frequency Phase Linearity Measurement (CF-PLM) para pares EEG-ECG, que medem a consistência das diferenças de fase entre pares de sinais ao longo do tempo. Antes de sua aplicação nos dados experimentais, esses métodos foram testados e validados por meio de sinais simulados, conforme descrito no Capítulo 6. A aplicação detalhada destas métricas está descrita no Capítulo 5.

4.4.4 Análise Estatística

Para avaliar diferenças entre condições experimentais, utilizamos métodos estatísticos robustos e não paramétricos. Gráficos e redes foram criados para visualizar os padrões de conectividade. Detalhes dessas análises estão disponíveis no Capítulo 5.

5 Pré-processamento de Dados

5.1 Preparação dos Dados

Os dados utilizados neste estudo foram coletados em sessões experimentais com atletas profissionais de basquetebol feminino, submetidas a condições de estimulação transcraniana por corrente contínua de alta definição (HD-tDCS) e a uma condição de controle (sham). Neste capítulo, descrevemos os procedimentos realizados para organizar, sincronizar e preparar os sinais de eletroencefalografia (EEG) e eletrocardiografia (ECG) para análise.

5.1.1 Organização Inicial dos Dados

Os dados de EEG e ECG foram armazenados em arquivos separados, correspondentes a cada atleta e condição experimental (*pre_sham*, *post_sham*, *pre_cathodic*, *post_cathodic*). Os sinais de EEG foram originalmente registrados a 1000 Hz, enquanto os sinais de ECG – obtidos a partir do EMG do músculo peitoral maior – foram registrados a 1111,11 Hz. Nesta etapa, os arquivos foram:

- Identificados e associados a cada atleta e condição;
- Renomeados e normalizados para garantir consistência;
- Submetidos a uma verificação de integridade para evitar erros no processamento.

5.1.2 Sincronização Temporal entre EEG e ECG

Devido ao início não sincronizado das gravações, foi necessário alinhar temporalmente os sinais de EEG e ECG. Com base em marcadores do período baseline, os seguintes passos foram realizados:

- Extração dos tempos de início e fim do baseline para cada modalidade;
- Remoção dos primeiros e últimos 15 segundos de cada gravação, minimizando artefatos de borda;
- Ajuste dos timestamps para que os sinais iniciassem simultaneamente;

5.1.3 Estruturação dos Dados

Após a sincronização, os dados foram organizados para o processamento subsequente. Os sinais de EEG foram armazenados em formato FIF, preservando as informações dos canais e os metadados, enquanto os dados de ECG foram exportados em formato CSV.

5.2 Pré-processamento dos Sinais

Esta seção descreve os procedimentos aplicados para garantir a qualidade dos sinais, incluindo filtragem, remoção de artefatos e segmentação.

5.2.1 Pré-processamento do EEG

5.2.1.1 Filtragem, Reamostragem e Preparação dos Dados de EEG

O processamento dos dados de EEG envolveu as seguintes etapas:

- **Aquisição e Carregamento:** Os dados brutos foram baixados do Google Drive e carregados via MNE-Python a partir de arquivos exportados do software BrainVision (ou, alternativamente, em formato EEGLAB). Após o carregamento, os canais foram renomeados conforme uma convenção padronizada (por exemplo, Fp1, Fz, F3, etc.) e canais irrelevantes foram removidos. (Ver Figura 1)
- **Aplicação de Montage:** Foi aplicado o montage padrão *standard_1005* para assegurar a correta localização dos eletrodos, conforme ilustrado no diagrama do sistema 10-20. (Ver Figura 2)
- **Definição do Período de Análise:** Com base nas informações extraídas dos arquivos de baseline, os dados foram recortados para um intervalo que excluiu os primeiros e últimos 15 segundos da gravação, reduzindo artefatos de borda.
- **Filtragem:** Aplicou-se um filtro passa-banda entre 0,5 e 60 Hz para eliminar ruídos fora do intervalo de interesse, seguido de um filtro notch em 60 Hz para remover interferências da rede elétrica.
- **Reamostragem:** Para padronizar a taxa de amostragem e facilitar o alinhamento com outros sinais (como o ECG), os dados de EEG foram reamostrados para 500 Hz.

5.2.1.2 Limpeza de Artefatos e Remoção de Componentes de Ruído (ICA)

Para aprimorar a qualidade dos sinais de EEG, foi empregada a Análise de Componentes Independentes (ICA) conforme as seguintes etapas:

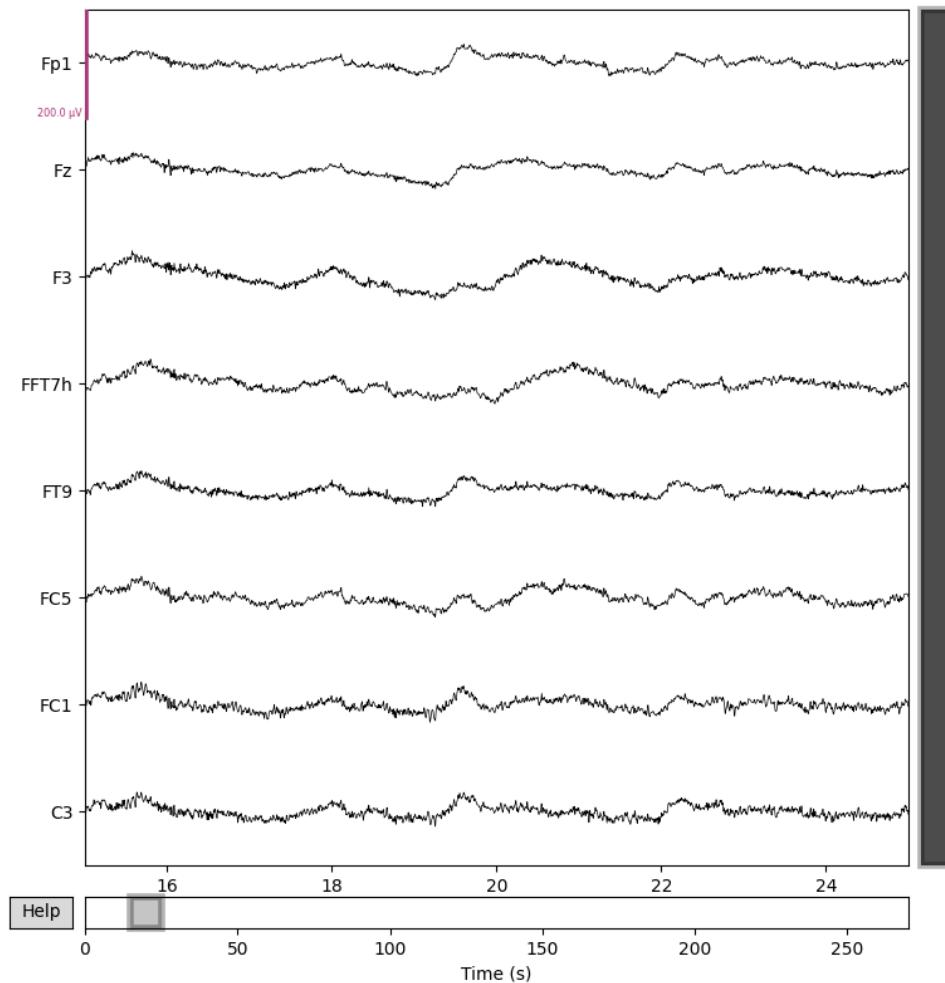


Figura 1 – Exemplo de sinais brutos de EEG, ilustrando a variação natural dos canais ao longo do tempo.

- **Definição dos Componentes:** O número de componentes foi definido igual ao número de canais bons disponíveis (excluindo os canais previamente identificados como ruins por inspeção visual).
- **Aplicação do ICA:** Utilizou-se o método FastICA para decompor o sinal, preservando as informações críticas para a análise de sincronicidade.
- **Estimativa de Parâmetros de Rejeição:** A biblioteca *autoreject* foi empregada para determinar, através de épocas de duração fixa, os limites ideais para rejeição de artefatos.
- **Identificação Automática de Artefatos:** Componentes relacionados a artefatos oculares (usando canais como Fp1 e Fp2) e à atividade cardíaca foram identificados automaticamente. Adicionalmente, uma análise baseada na curtose foi realizada para detectar componentes com alta amplitude, indicativos de artefatos.
- **Inspeção Visual e Seleção:** Foram gerados gráficos das propriedades dos componentes e uma visualização interativa, inclusive com animação GIF, que permitiram a

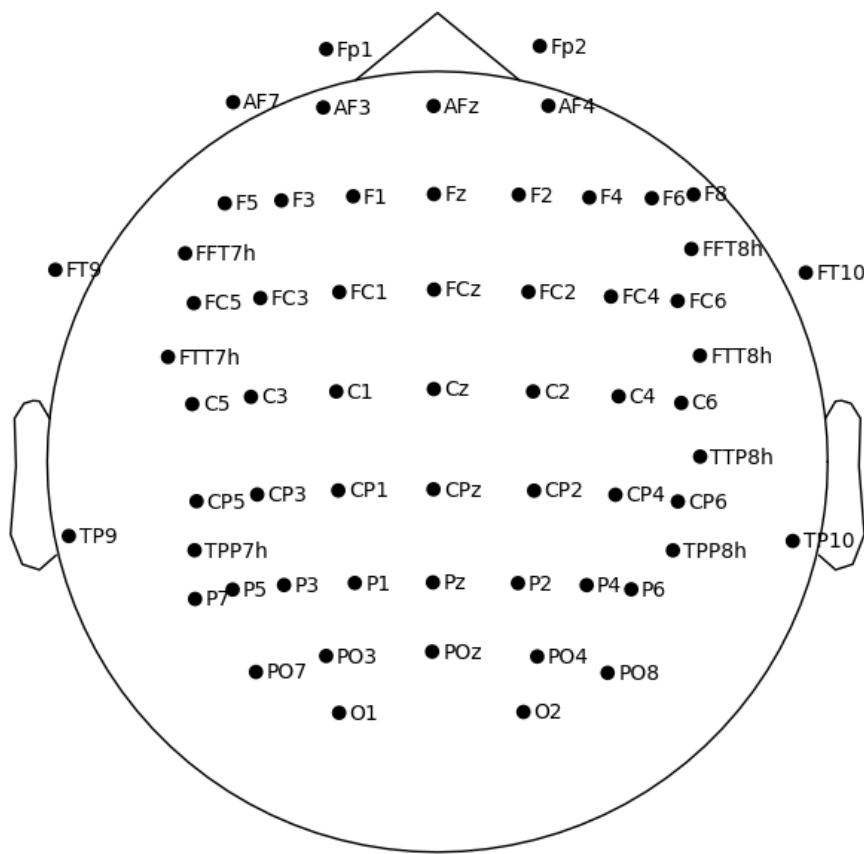


Figura 2 – Diagrama do sistema 10-20, demonstrando a localização padronizada dos eletrodos no couro cabeludo.

inspeção manual dos componentes para decidir quais excluir. (Ver Figuras 3)

- **Aplicação e Salvamento:** Após a definição dos componentes a serem removidos, o ICA foi aplicado para eliminar os artefatos identificados, gerando um sinal de EEG limpo, que foi salvo em formato FIF para futuras análises.

5.2.2 Pré-processamento do Sinal de ECG

O processamento do sinal de ECG foi realizado com o objetivo de obter uma versão limpa e refinada do sinal, que permitisse a detecção precisa dos R-peaks e a extração de informações de fase. As etapas foram organizadas da seguinte forma:

5.2.2.1 Aquisição e Segmentação dos Dados de ECG

- **Aquisição:** Os dados de ECG foram coletados juntamente com informações sobre os tempos de início e fim do período de baseline para cada condição experimental, garantindo a correta identificação dos intervalos de interesse para análise.

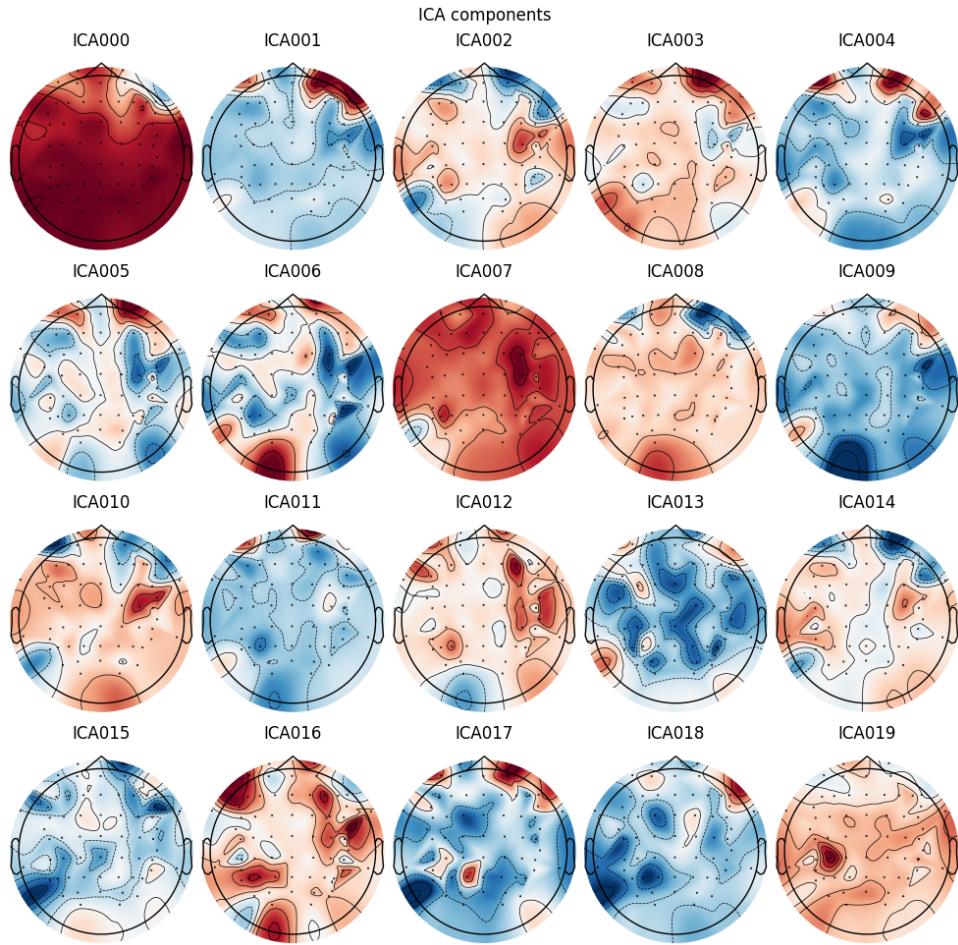


Figura 3 – Componentes obtidos após a aplicação do ICA, com mapas topográficos que evidenciam a distribuição espacial de cada componente.

- **Segmentação:** Com base nos tempos extraídos dos arquivos de baseline, o sinal bruto foi segmentado para selecionar apenas o intervalo correspondente à condição de interesse. Para reduzir artefatos nas bordas, os primeiros e últimos 15 segundos foram removidos.

5.2.2.2 Limpeza do Sinal e Detecção de Picos

- **Limpeza:** Utilizou-se a biblioteca NeuroKit2 para processar o sinal segmentado e remover ruídos, gerando uma versão limpa do ECG.
- **Detecção Automática de Picos:** Foi aplicado um algoritmo para detecção automática dos picos R (R-peaks) no sinal limpo, identificando os batimentos cardíacos. A Figura 5 ilustra um exemplo em que o sinal bruto (cinza) é sobreposto ao sinal limpo (azul), enquanto os picos R são marcados em vermelho.
- **Correção Manual dos Picos R:** Após a detecção automática, foi realizada uma inspeção visual cuidadosa utilizando gráficos interativos para identificar:

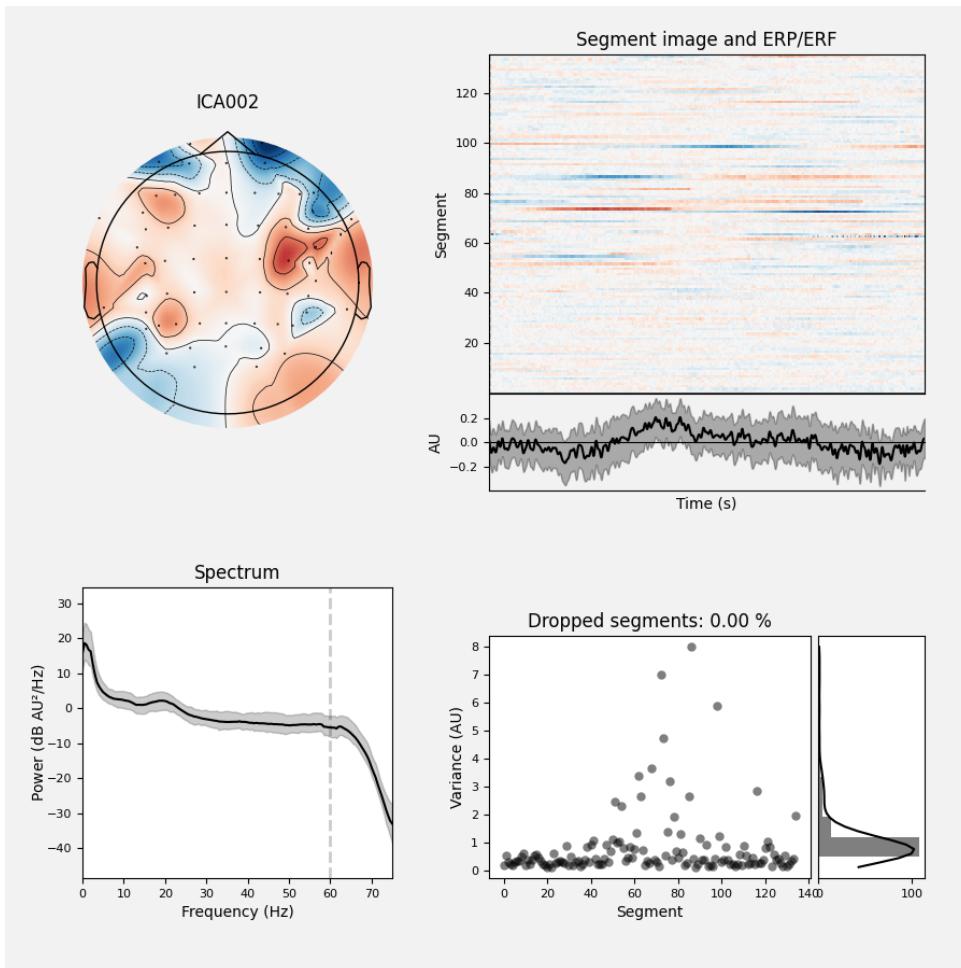


Figura 4 – Análise detalhada de um componente ICA, apresentando o mapa topográfico, o espectro de frequência e outras características relevantes para a identificação de artefatos.

- Ausência de picos em locais onde deveriam ocorrer, com inserção manual dos picos faltantes por meio da identificação precisa dos timestamps correspondentes.
- Presença de picos falsos em regiões sem batimentos válidos, com remoção manual desses picos com base nos timestamps detectados como incorretos.

Esse ajuste garante a acurácia na identificação dos batimentos cardíacos, evitando tanto a omissão quanto a inclusão indevida de eventos.

5.2.2.3 Aplicação de Filtros Complementares

Para refinar a definição dos eventos do ECG, foram aplicados filtros adicionais:

- **Filtro de Janela:** Extração de uma janela de ± 50 ms ao redor de cada pico, isolando os segmentos de interesse.
- **Filtro de Cruzamento pelo Zero:** Identificação dos pontos de cruzamento pelo zero nos segmentos próximos aos picos, para um ajuste fino dos limites dos eventos.

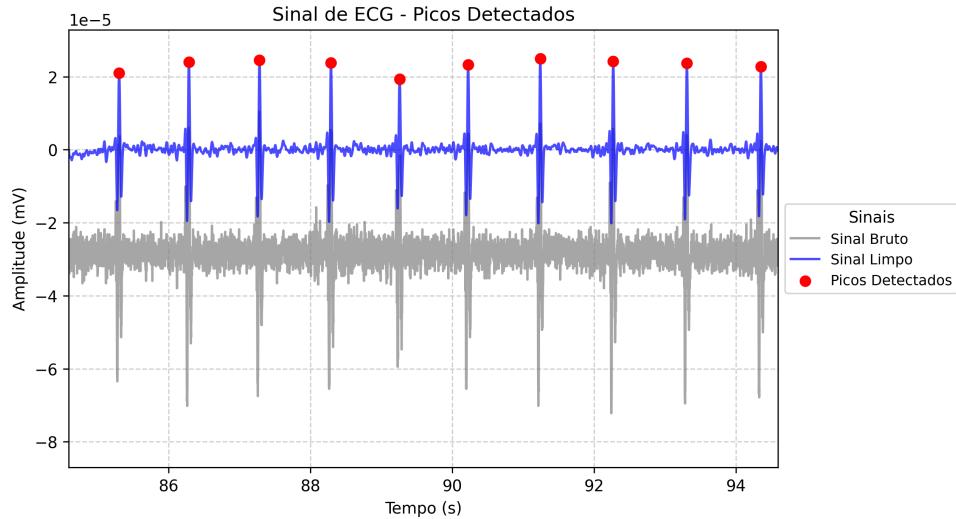


Figura 5 – Sinal de ECG com picos detectados. O sinal bruto (cinza) é sobreposto pelo sinal limpo (azul), enquanto os picos R são marcados em vermelho.

A combinação desses filtros resultou em um *Sinal Final Filtrado*, que destaca de forma mais clara a morfologia do ECG. A Figura 6 exemplifica o efeito dos filtros, comparando o sinal limpo inicial (linha colorida) e o sinal final filtrado, bem como os picos detectados.

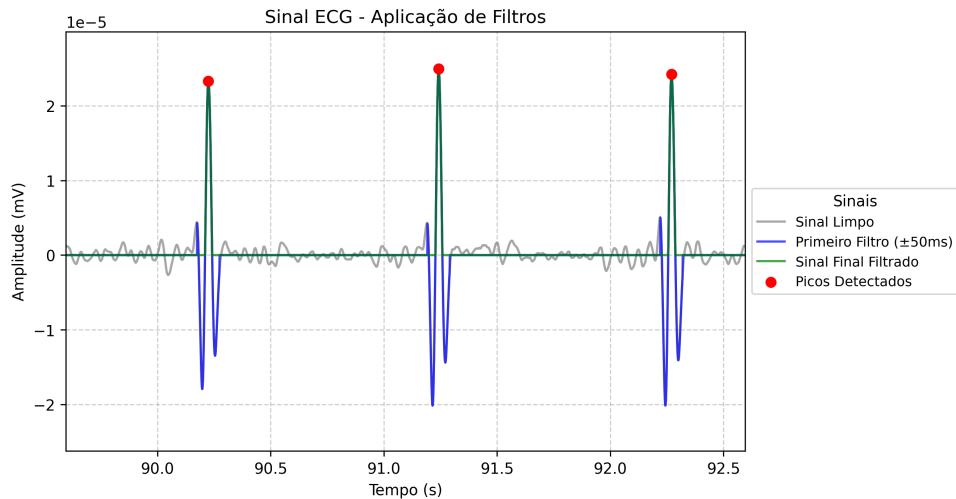


Figura 6 – Aplicação de filtros complementares ao sinal de ECG, destacando a morfologia dos picos R (em vermelho).

5.2.2.4 Geração de Sinais Senoidais e Análise de Fase

Para aprimorar a análise de sincronização de fase entre os sinais de EEG e ECG, o sinal de ECG foi transformado em uma representação senoidal. Essa transformação foi adotada pelos seguintes motivos:

- **Definição Clara do Ciclo Cardíaco:** Ao utilizar os R-peaks para delimitar cada ciclo, a transformação em uma onda senoidal permite definir de forma inequívoca o

início e o fim do ciclo cardíaco, proporcionando um marcador preciso para segmentar os períodos de interesse.

- **Extração Precisa da Fase:** Uma onda senoidal apresenta uma variação linear de fase ao longo do tempo, o que facilita a extração da fase instantânea por meio da Transformada de Hilbert. Essa linearidade contribui para uma determinação mais robusta e consistente da fase, essencial para análises de sincronização.
- **Facilitação da Análise de Sincronização:** Técnicas de sincronização de fase, como o CF-PLM (uma variante do PLV para análise cross-frequency), funcionam melhor quando a fase é clara e bem definida. A representação senoidal torna a fase do ECG mais nítida, permitindo que os algoritmos capturem de forma mais precisa a relação de sincronização entre os ritmos neurais (EEG) e o ritmo cardíaco.
- **Robustez à Variabilidade e Ruído:** O ECG bruto possui características de pico acentuado e variabilidade que podem dificultar a obtenção de uma fase contínua e suave. Ao converter o sinal para uma forma senoidal, essas irregularidades são suavizadas, o que melhora a robustez do método de extração de fase mesmo em presença de ruídos ou artefatos.
- **Integração com a Análise de EEG:** Como os sinais de EEG são frequentemente filtrados para se aproximarem de formas quase senoidais, padronizar a representação do ECG para uma forma senoidal facilita a integração dos dois tipos de sinais na análise de sincronização, permitindo comparações diretas e métodos de análise cross-frequency mais eficazes.

A Figura 7 ilustra a comparação de fase entre o sinal de ECG filtrado, o sinal senoidal gerado e um sinal simulado, evidenciando a coerência de fase entre eles.

Em suma, a transformação do ECG em um sinal senoidal não apenas define de forma clara o ciclo cardíaco, mas também possibilita a extração de uma fase contínua, fundamental para a análise de sincronização de fase entre EEG e ECG utilizando métodos que envolvam extração de fase, tais quais os utilizados neste estudo.

5.2.2.5 Estrutura do Dado Final e Armazenamento

O DataFrame final resultante do processamento do ECG integra:

- **Tempo:** Timestamps sincronizados.
- **Sinal Bruto (EMG):** Valor original do sinal.
- **Sinal Limpo (ECG):** Versão filtrada do sinal.

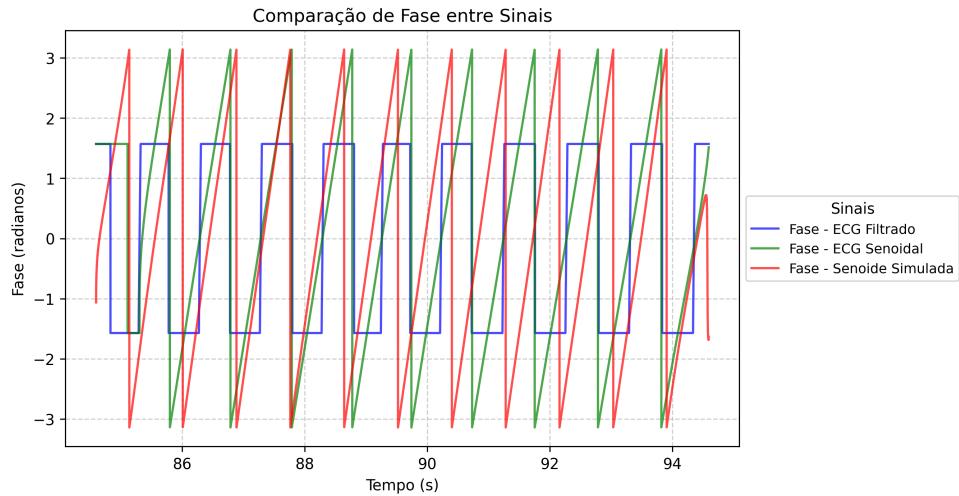


Figura 7 – Comparação de fase entre o ECG filtrado (azul), o ECG senoidal (verde) e um sinal simulado (vermelho). A boa concordância entre as fases indica que o procedimento de geração do sinal senoidal e a extração de fase são consistentes.

- **Picos:** Indicador binário dos R-peaks detectados.
- **First Filtered:** Sinal obtido após a aplicação do filtro de janela (± 50 ms).
- **Final Filtered:** Sinal final obtido após a combinação dos filtros.
- **ECG Senoidal:** Sinal senoidal derivado dos R-peaks.

Este conjunto de dados foi exportado em formato CSV.

Parte IV

Análises e Resultados

6 Métodos de Análise de Sincronização de Fase

Neste capítulo, apresentamos os fundamentos teóricos e práticos dos métodos utilizados para analisar a sincronização de fase entre sinais fisiológicos. Em particular, discutiremos o Phase Lag Index (PLI) e o Cross-Frequency Phase Linearity Measurement (CF-PLM). Também foi testado o tradicional Phase Locking Value (PLV) para comparação e os resultados obtidos com o PLV estão disponíveis no anexo para referência. Para este estudo, optamos por utilizar o PLI para a sincronização entre canais de EEG (same-frequency) e o CF-PLM para a análise entre EEG e ECG (cross-frequency).

6.1 Fundamentos dos Métodos

A análise de sincronização de fase visa quantificar a consistência da diferença de fase entre dois sinais ao longo do tempo. Os métodos utilizados neste estudo são baseados em abordagens que extraem a fase instantânea dos sinais por meio da Transformada de Hilbert, permitindo a análise de como as fases se relacionam entre si.

6.1.1 Phase Lag Index (PLI)

O PLI é um índice amplamente utilizado para medir a sincronização de fase entre sinais que operam na mesma faixa de frequência, como os canais de EEG dentro de uma mesma banda. Ao contrário do Phase Locking Value (PLV), o PLI é robusto à mistura de sinais e aos efeitos de condução de volume, pois foca na assimetria da distribuição das diferenças de fase. Especificamente, ele desconsidera valores próximos de zero que podem resultar de sincronizações espúrias, muitas vezes induzidas por fontes comuns ou artefatos, concentrando-se apenas em atrasos de fase que são mais informativos sobre a interação funcional.

Conforme discutido por ?? (?), o PLI apresenta vantagens metodológicas, fornecendo uma medida mais pura da sincronização de fase, uma vez que elimina a influência de picos que podem ocorrer devido a volume conduction ou outras fontes de ruído. Essa robustez torna o PLI particularmente adequado para a avaliação da sincronização entre canais de EEG, onde a variabilidade e a interferência de sinais de fundo podem comprometer a precisão de medidas tradicionais como o PLV.

Além disso, o PLI é eficaz na detecção de atrasos sistemáticos entre os sinais, contribuindo para uma melhor compreensão da dinâmica funcional cerebral. No entanto,

vale ressaltar que, para interações entre sinais que operam em frequências distintas (por exemplo, entre EEG e ECG), métodos como o CF-PLM são mais indicados. Nesta pesquisa, optamos por utilizar o PLI para a análise de sincronização entre canais de EEG em bandas idênticas, enquanto empregamos o CF-PLM para investigar a sincronização cross-frequency entre EEG e ECG. Os resultados comparativos obtidos com o PLV também foram testados e estão disponíveis no anexo para referência.

6.1.2 Cross-Frequency Phase Linearity Measurement (CF-PLM)

O CF-PLM é um método desenvolvido para analisar a sincronização de fase entre sinais que operam em frequências distintas, ou seja, para detectar acoplamento cross-frequency. Essa abordagem é especialmente útil para avaliar a relação entre os ritmos neurais do EEG (tipicamente de alta frequência) e o ritmo cardíaco do ECG (geralmente de baixa frequência).

De acordo com ?? (??), o método estende o conceito de Phase Linearity Measurement (PLM) para a análise de n:m sincronização entre sinais, sem a necessidade de hipóteses a priori sobre as frequências envolvidas. O procedimento baseia-se nos seguintes passos:

- Cálculo dos Sinais Analíticos:** Para os sinais de interesse $x(t)$ e $y(t)$, obtém-se suas representações analíticas $x_{\text{an}}(t)$ e $y_{\text{an}}(t)$ por meio da Transformada de Hilbert, que fornecem, respectivamente, as fases $\phi_x(t)$ e $\phi_y(t)$.

- Construção do Sinal Interferométrico:** Calcula-se o sinal interferométrico $z(t)$ utilizando a fórmula:

$$z(t) = \frac{x_{\text{an}}(t) y_{\text{an}}^*(t)}{|x_{\text{an}}(t)| |y_{\text{an}}(t)|} = e^{i\Delta\phi(t)},$$

onde $\Delta\phi(t) = \phi_x(t) - \phi_y(t)$ é a diferença de fase instantânea entre os sinais. Note que $z(t)$ possui amplitude unitária, isolando assim a informação de fase.

- Análise da Densidade Espectral de Potência (PSD):** Através da Transformada de Fourier, calcula-se a PSD de $z(t)$. Em condições de acoplamento iso-frequencial, o pico na PSD é centralizado em $f = 0$. Já em condições de acoplamento cross-frequency, a presença de um desvio (i.e., um pico deslocado de zero) indica a diferença entre as frequências centrais dos sinais.

- Cálculo do CF-PLM:** O índice CF-PLM é obtido integrando a PSD em uma janela estreita $[f_\Delta - B, f_\Delta + B]$ centrada no pico (onde f_Δ representa a diferença de frequência entre os sinais) e normalizando pelo poder total da PSD:

$$\text{CF-PLM} = \frac{\int_{f_\Delta-B}^{f_\Delta+B} SZ(f) df}{\int_{-\infty}^{+\infty} SZ(f) df}.$$

A transformação do ECG em uma representação senoidal (conforme descrito no Capítulo 5) é crucial para que a extração da fase seja clara e contínua, o que, por sua vez, melhora a detecção de sincronização cross-frequency entre os sinais de EEG e ECG. Essa abordagem permite que o CF-PLM capture com precisão a intensidade do acoplamento, sem que a amplitude dos sinais influencie o índice, tornando-o robusto à variabilidade dos dados.

Em resumo, o CF-PLM possibilita uma estimativa confiável da sincronização de fase entre sinais de frequências diferentes, sendo particularmente indicado para a análise de interações entre os ritmos neurais e o ritmo cardíaco, conforme validado por ?? (??).

6.1.3 Comparação com o Phase Locking Value (PLV)

Para fins de validação e comparação, também testamos o PLV, um método tradicional e amplamente utilizado para a análise de sincronização de fase. Conforme destacado por ?? (??), embora o PLV seja intuitivo e eficaz na medição da consistência da diferença de fase entre sinais na mesma faixa de frequência, ele apresenta limitações notáveis, como a sua sensibilidade a ruídos e aos efeitos de volume conduction, que podem levar à detecção de sincronizações espúrias.

Essas limitações se tornam ainda mais evidentes na análise cross-frequency, onde os sinais operam em escalas de frequência distintas. Em nossa investigação, os resultados obtidos com o PLV foram utilizados para contrastar a sensibilidade e a robustez dos métodos alternativos: o PLI, para sincronização iso-frequencial entre canais de EEG, e o CF-PLM, para a análise de acoplamento cross-frequency entre EEG e ECG. Os resultados experimentais confirmaram que, embora o PLV seja adequado para sinais com a mesma faixa de frequência, ele não captura de maneira confiável a sincronização entre sinais de diferentes frequências, corroborando as observações de Seraj (2018).

Portanto, optamos por utilizar o PLI e o CF-PLM como índices principais neste estudo. Detalhes comparativos e resultados do PLV, que evidenciam suas limitações e complementam nossa análise, estão disponíveis no anexo.

6.2 Validação Experimental com Injeção de Sinais

Para validar os métodos utilizados neste estudo, realizamos experimentos com injeção controlada de sinais senoidais sobre dados reais de ECG e EEG, adquiridos durante sessões experimentais reais. O objetivo foi verificar a capacidade dos índices CF-PLM, PLV e PLI em identificar corretamente diferentes tipos e intensidades de sincronização de fase artificialmente introduzidas.

A técnica empregada consistiu nas seguintes etapas:

1. Seleção de segmentos representativos dos sinais originais de ECG e EEG.
2. Geração de sinais senoidais com frequências e fases específicas utilizando o modelo de Kuramoto, permitindo controle preciso das condições experimentais.
3. Aplicação controlada desses sinais sobre os sinais originais usando máscaras de injeção, variando a porcentagem de contribuição (0%, 25%, 50%, 75% e 100%) dos sinais injetados.
4. Cálculo dos índices CF-PLM, PLV e PLI sobre esses sinais modificados, para avaliar o desempenho dos métodos de sincronização propostos em diferentes cenários.

Foram conduzidos três cenários principais:

- **Cross-frequency (1 Hz no ECG, 40 Hz no EEG):** Para testar especialmente o índice CF-PLM em situações onde o acoplamento ocorre entre frequências distintas.
- **Same-frequency (10 Hz no ECG e EEG com defasagem):** Para avaliar sensibilidade e desempenho de todos os índices quando os sinais apresentam frequências iguais, porém com defasagem de fase fixa configurada ($\pi/4$).
- **Same-frequency com phase lag zero (ambos 10 Hz sem defasagem):** Cenário idealizado para demonstrar a robustez do PLI contra sincronização espúria.

Exemplos dos sinais antes e após a injeção no cenário Cross-frequency são mostrados nas Figuras 8 e 9, ilustrando a adição de sinais artificiais em frequências distintas sobre o sinal original.

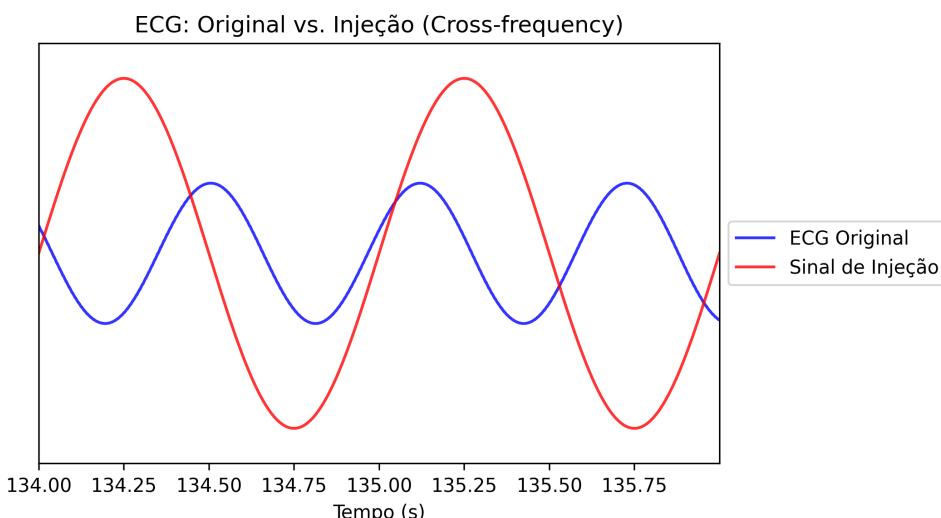


Figura 8 – ECG: comparação entre o sinal original e o sinal senoidal injetado (1 Hz), cenário Cross-frequency.

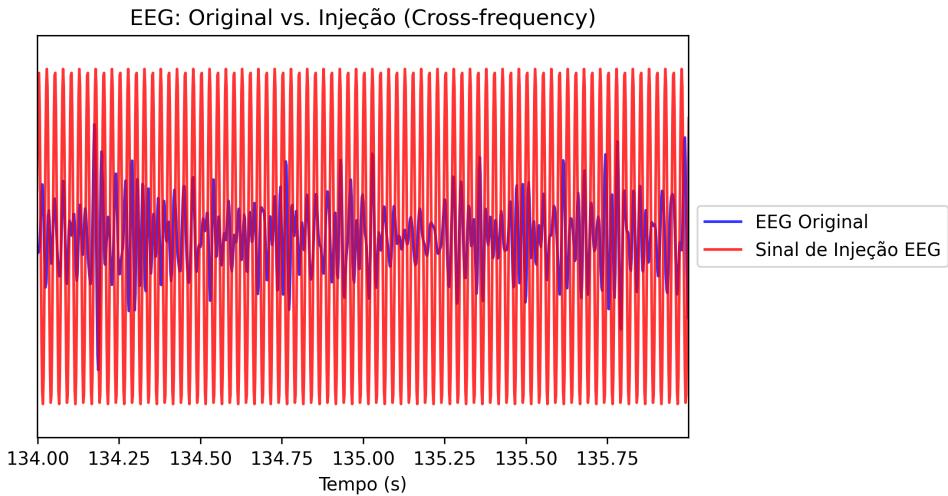


Figura 9 – EEG: comparação entre o sinal original e o sinal senoidal injetado (40 Hz), cenário Cross-frequency.

Já no cenário Same-frequency, onde tanto o ECG quanto o EEG recebem sinais senoidais da mesma frequência (10 Hz) mas com pequena defasagem ($\pi/4$), temos os resultados ilustrados pelas Figuras 10 e 11. Esses gráficos destacam visualmente a interferência resultante da injeção.

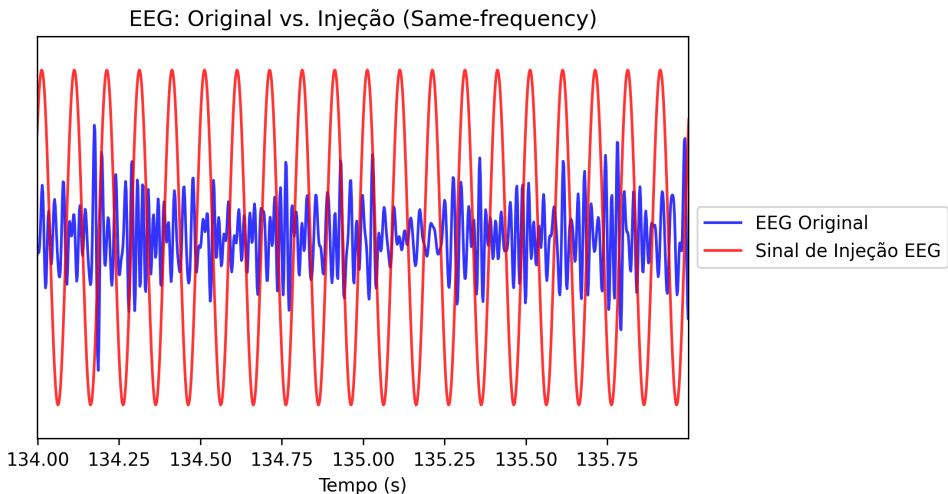


Figura 10 – EEG original (azul) e sinal de injeção de 10 Hz (vermelho) com pequena defasagem ($\pi/4$).

Em seguida, realizamos a extração das fases instantâneas usando a transformada de Hilbert e geramos o sinal interferométrico. Esses passos estão exemplificados visualmente nas Figuras 12 e 13.

A seguir, calculamos o índice CF-PLM utilizando a FFT sobre o sinal interferométrico, exemplificado pela Figura 14.

Finalmente, analisamos o cenário especial "Same-frequency Com Phase Lag Zero", onde as fases são perfeitamente sincronizadas. As Figuras 15 e 16 comprovam que o PLI é

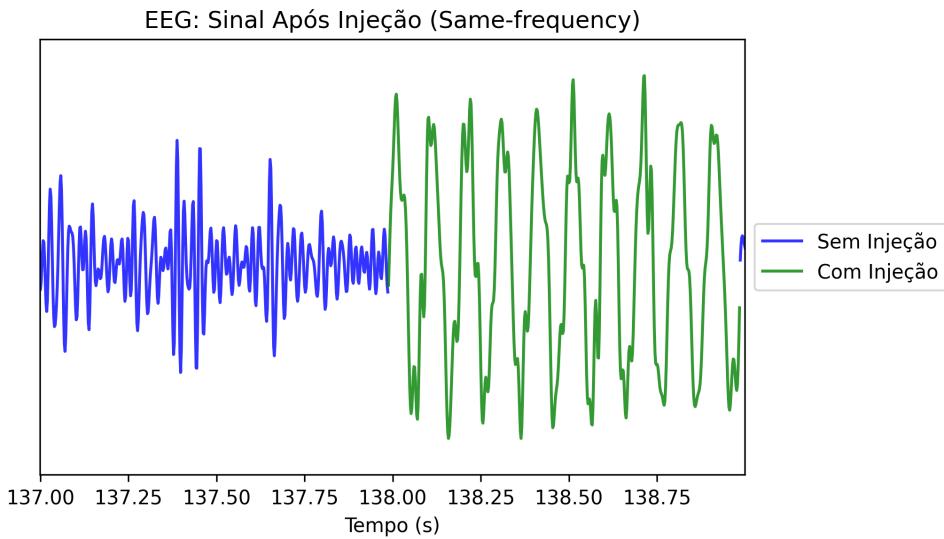


Figura 11 – Sinal de EEG após a injeção controlada de uma senóide (verde) comparado ao sinal original sem injeção (azul).

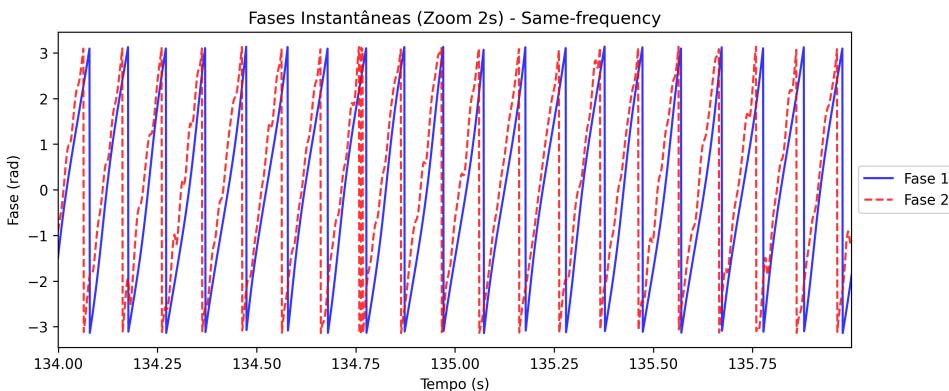


Figura 12 – Fases instantâneas extraídas dos sinais EEG e ECG injetados (ambos a 10 Hz).

efetivamente insensível a tais sincronizações.

O comportamento geral das métricas nos diferentes cenários e níveis de injeção está resumido na Figura 17.

Esses resultados justificam a escolha do CF-PLM para análise de sincronização entre ECG e EEG (cross-frequency) e do PLI para sincronização em frequências iguais, evitando detecção de acoplamentos triviais como em condução de volume (phase lag zero). O PLV é reportado apenas para referência complementar devido à sua sensibilidade elevada em condições triviais.

6.3 Análise de Conectividade ao Longo do Tempo

Para investigar a dinâmica da sincronização ao longo da sessão experimental, o sinal foi dividido em janelas de 10 segundos, ao longo da gravação total de 4 minutos e

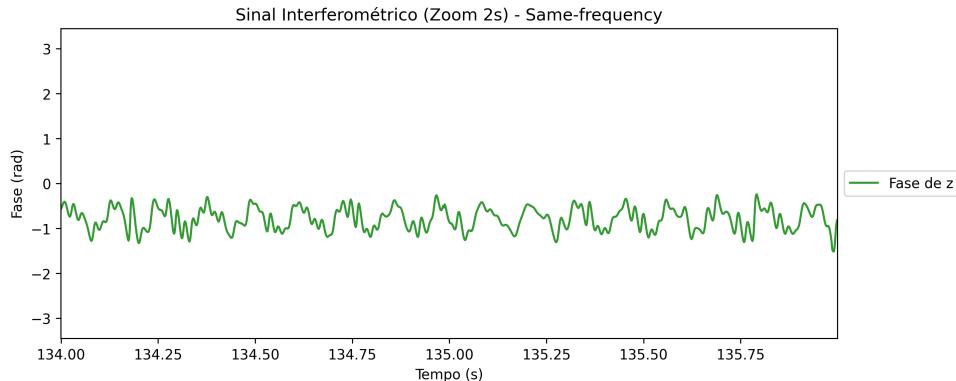


Figura 13 – Sinal interferométrico gerado pela diferença de fase instantânea (cenário same-frequency).

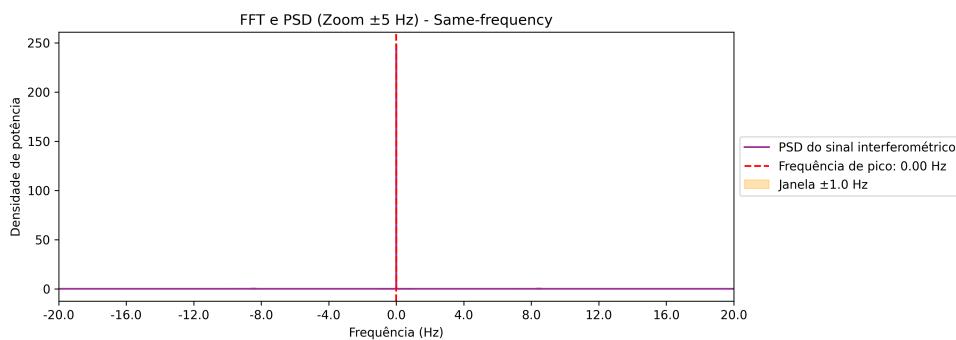


Figura 14 – PSD do sinal interferométrico, indicando o pico em 0 Hz devido ao offset constante de fase entre os sinais de mesma frequência.

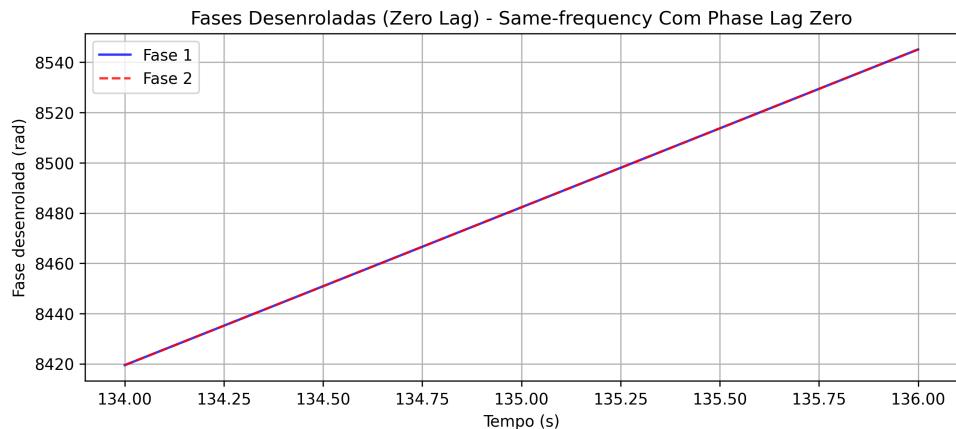


Figura 15 – Fases desenroladas em cenário sem defasagem (10 Hz), com sobreposição quase exata dos sinais.

30 segundos de cada coleta. Em cada janela, foi calculada uma medida de sincronicidade (PLI, PLV ou CF-PLM) para cada par de canais, para cada banda de frequência, para cada condição (cathodic e sham) e para cada atleta. Em seguida, a mediana desses valores foi extraída, fornecendo uma medida robusta da conectividade ao longo do tempo para cada configuração.

Essa abordagem permite visualizar a evolução temporal da sincronização e comparar

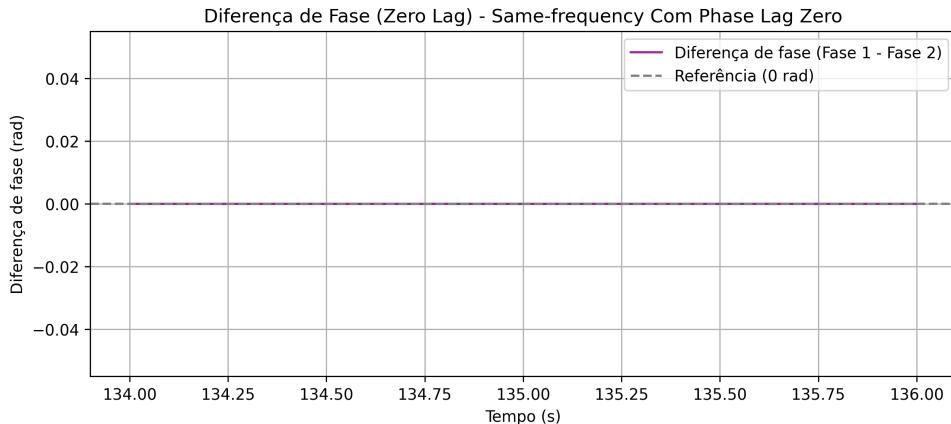


Figura 16 – Diferença de fase próxima a zero, indicando ausência completa de defasagem no cenário de Phase Lag Zero.

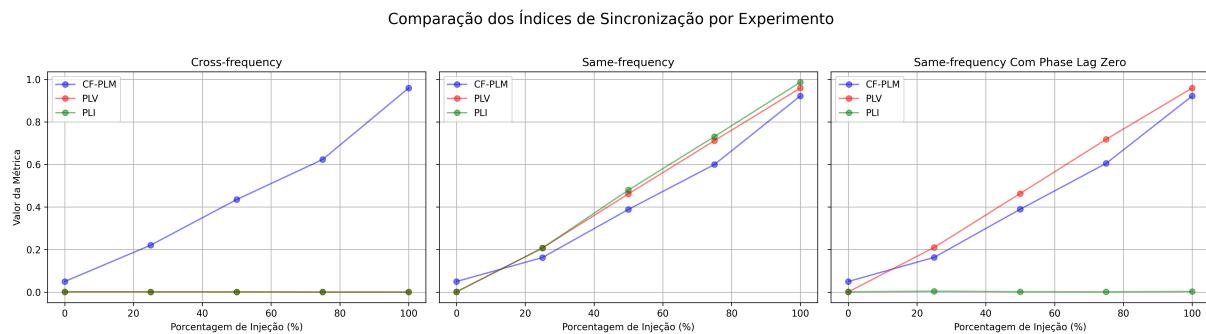


Figura 17 – Comparação dos índices CF-PLM, PLV e PLI nos três cenários estudados, em função da porcentagem de injeção aplicada.

a estabilidade dos diferentes índices. Ressalta-se que, em nossas análises, enfatizamos o *Wilcoxon RBC* e o p-valor corrigido por Bonferroni como os principais indicadores de tamanho de efeito e significância estatística, respectivamente, dada sua robustez em contextos não paramétricos e na presença de variabilidade e outliers.

A seguir, são apresentadas as séries temporais obtidas para três métricas principais:

- **CF-PLM (EEG-ECG):** A Figura 18 mostra a mediana do CF-PLM ao longo do tempo para a condição cathodic, refletindo a sincronização cross-frequency entre EEG e ECG.
- **PLI (EEG-EEG):** A Figura 19 apresenta a mediana do PLI ao longo do tempo para a condição cathodic, indicando a sincronização iso-frequencial entre canais cerebrais.
- **PLV (EEG-EEG):** A Figura 20 exibe a mediana do PLV ao longo do tempo para a condição cathodic, utilizada aqui para comparação, pois o PLV é mais sensível a ruídos e efeitos de volume conduction.

Cada gráfico é construído a partir dos valores calculados em janelas de 10 segundos e a mediana de cada janela foi utilizada para representar a medida de sincronicidade de forma robusta, minimizando o impacto de variações pontuais e outliers.

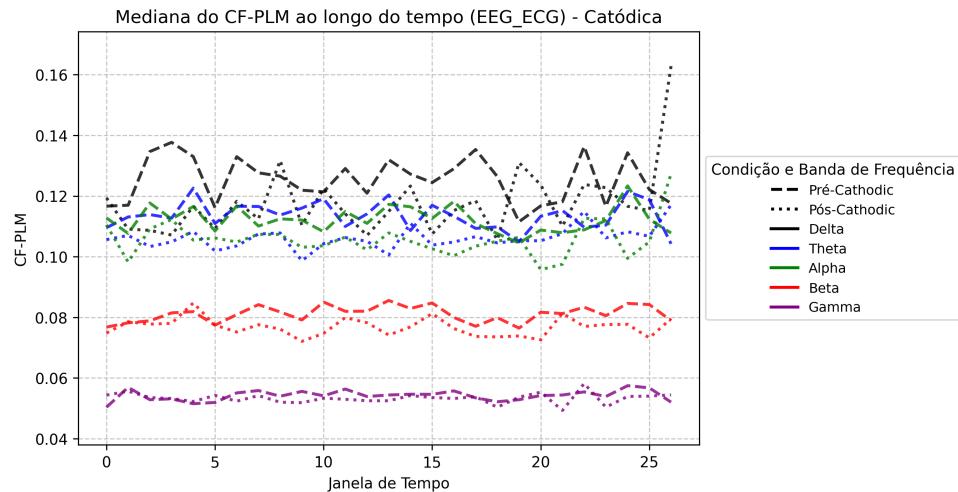


Figura 18 – Mediana do CF-PLM ao longo do tempo para a condição cathodic (EEG-ECG). Cada ponto representa a mediana da medida de sincronicidade calculada em janelas de 10 segundos, evidenciando a evolução do acoplamento cross-frequency entre EEG e ECG.

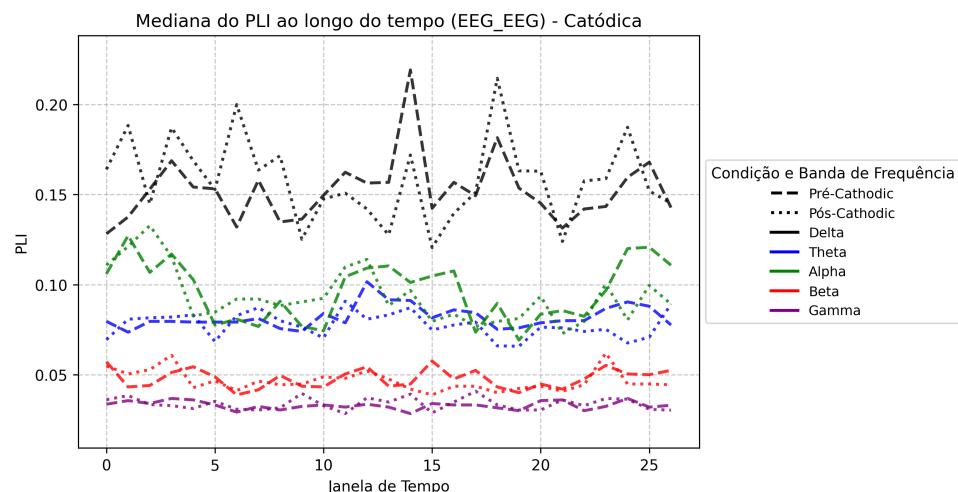


Figura 19 – Mediana do PLI ao longo do tempo para a condição cathodic (EEG-EEG). O gráfico mostra como a sincronização iso-frequencial entre canais cerebrais varia ao longo da gravação.

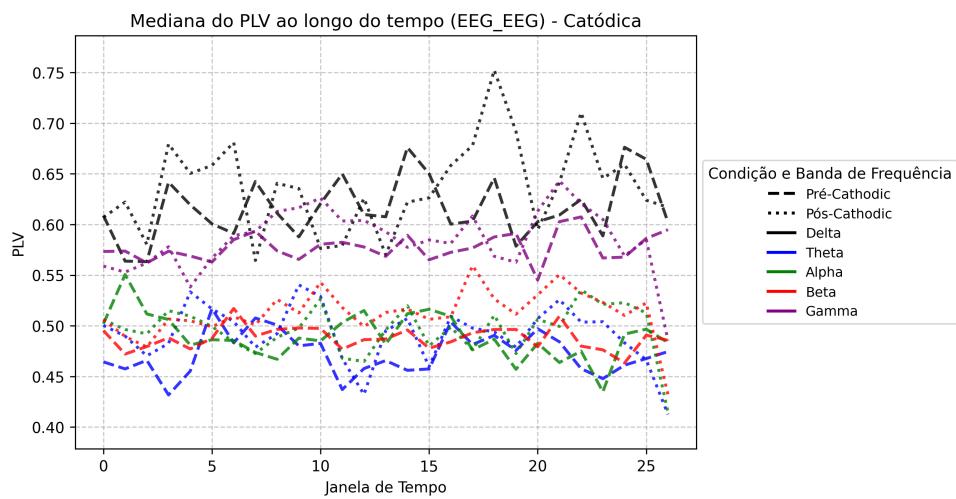


Figura 20 – Mediana do PLV ao longo do tempo para a condição cathodic (EEG-EEG). Este índice serve para comparação com o PLI, embora seja mais sensível a ruídos e efeitos de volume conduction.

7 Análise de Distribuição e Normalidade

Nesta seção, investigamos a forma das distribuições das métricas de conectividade, tanto nos seus valores “puros” quanto nas diferenças (median_diff) entre condições (Pós – Pré). Inicialmente, apresentamos os histogramas das métricas originais extraídas dos sinais (PLI e CF-PLM), e em seguida, explicamos que para testar o efeito da estimulação, calculamos a diferença entre os valores pós e pré (por exemplo, pós-sham menos pré-sham). Finalmente, são apresentados os histogramas das diferenças e discutidas as implicações para a escolha dos testes estatísticos.

7.1 Distribuição das Métricas de Conectividade (PLI e CF-PLM)

7.1.1 Distribuição dos Valores Puros

Antes de subtrair os valores pré dos pós, as métricas de conectividade (PLI, PLV e CF-PLM) são extraídas diretamente dos sinais, refletindo as medidas originais sem a influência do efeito de estimulação. As figuras a seguir ilustram as distribuições “puras” dessas métricas para os diferentes grupos de canais (EEG-EEG e EEG-ECG) e faixas de frequência (delta, theta, alpha, beta e gamma).

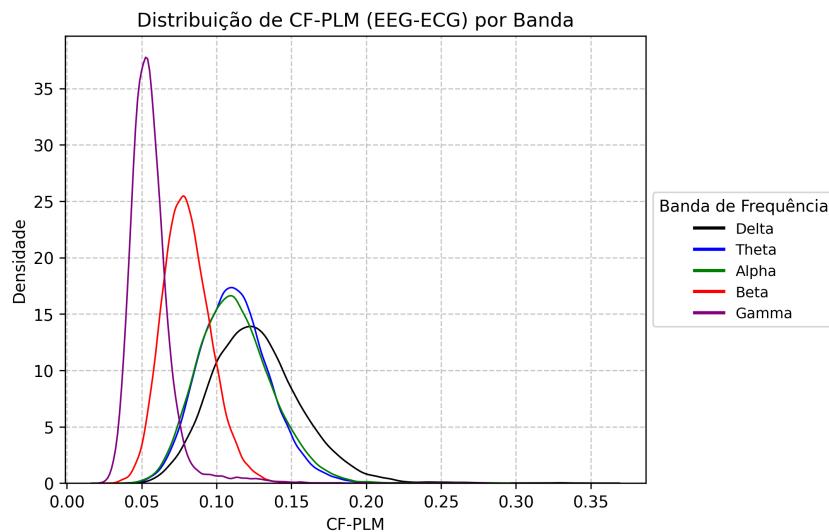


Figura 21 – Distribuição de CF-PLM (EEG-ECG) por banda. Observa-se a concentração dos valores em torno de faixas mais baixas (próximas de 0), com maior densidade para a banda delta (linha vermelha) e theta (linha azul).

No geral, observa-se que:

- **EEG-ECG:** As métricas PLI e PLV concentram-se em valores muito baixos, indicando fraca sincronização de fase iso-frequencial entre o ritmo cardíaco e o sinal

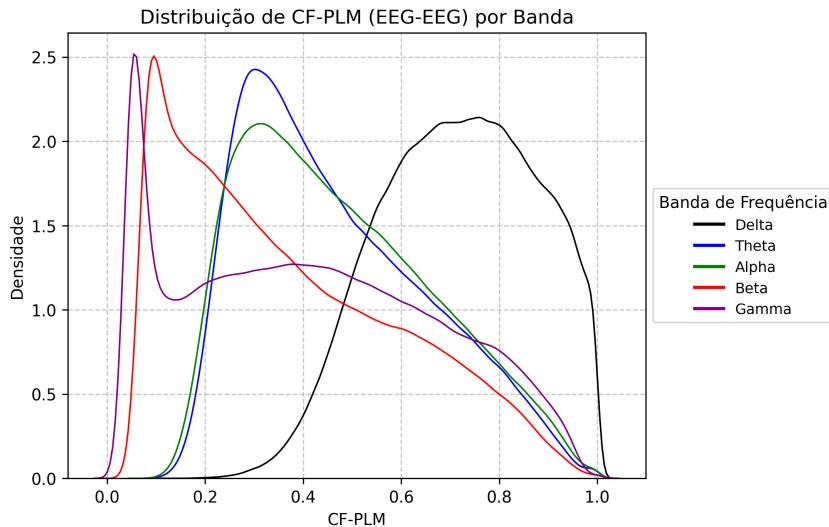


Figura 22 – Distribuição de CF-PLM (EEG-EEG) por banda. Nesse caso, alguns pares apresentam valores mais elevados, evidenciando maior acoplamento *cross-frequency* dentro do EEG, especialmente em alpha e gamma.

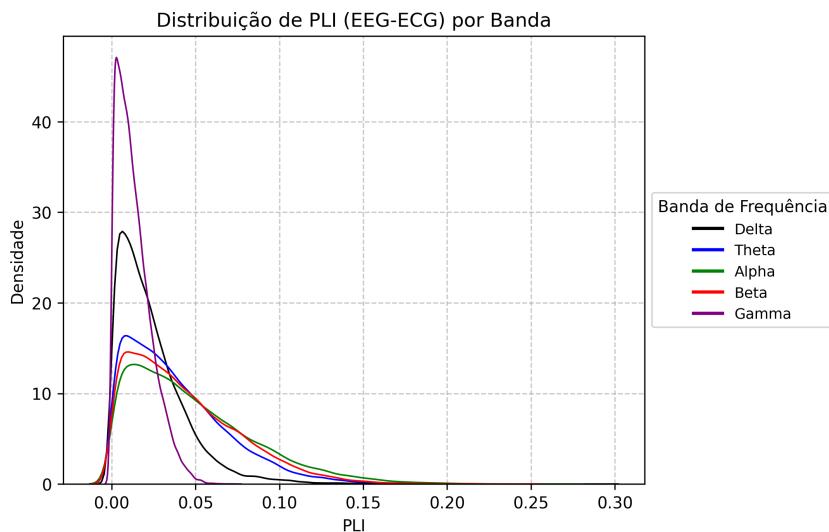


Figura 23 – Distribuição de PLI (EEG-ECG) por banda. Os valores tendem a se concentrar muito próximos de zero, sugerindo que a maioria dos pares EEG-ECG não apresenta *phase lag* robusto em bandas iso-frequenciais.

cerebral. Em contrapartida, o CF-PLM apresenta valores um pouco maiores, apontando para um acoplamento *cross-frequency* pontual.

- **EEG-EEG:** Tanto PLI quanto PLV exibem distribuições que podem se estender para valores mais altos, sugerindo a presença de sincronizações mais robustas entre canais cerebrais na mesma banda. O CF-PLM, por sua vez, chega a atingir níveis ainda maiores, evidenciando interações entre faixas de frequência distintas (p. ex. oscilações lentas e rápidas).

Essas observações fornecem uma visão inicial sobre o comportamento das métricas

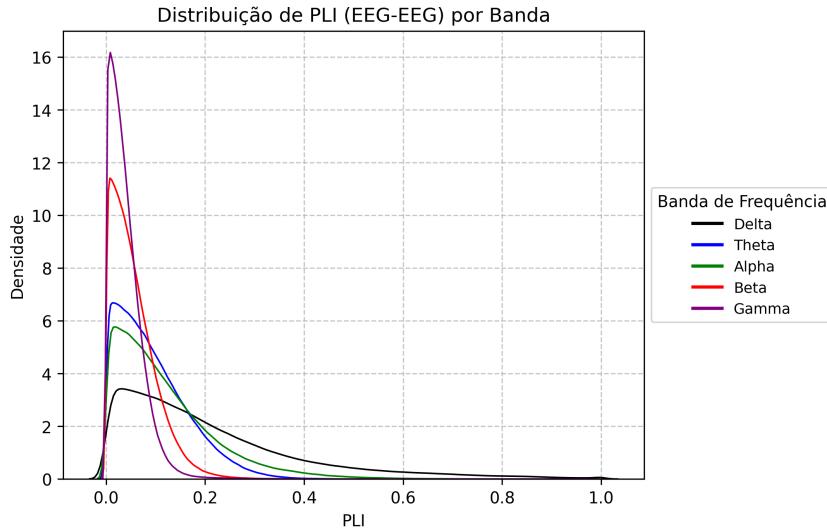


Figura 24 – Distribuição de PLI (EEG-EEG) por banda. Embora a maior parte dos valores se concentre em torno de zero, algumas bandas (como alpha e gamma) apresentam caudas mais extensas, indicando pares de canais com defasagem de fase mais consistente.

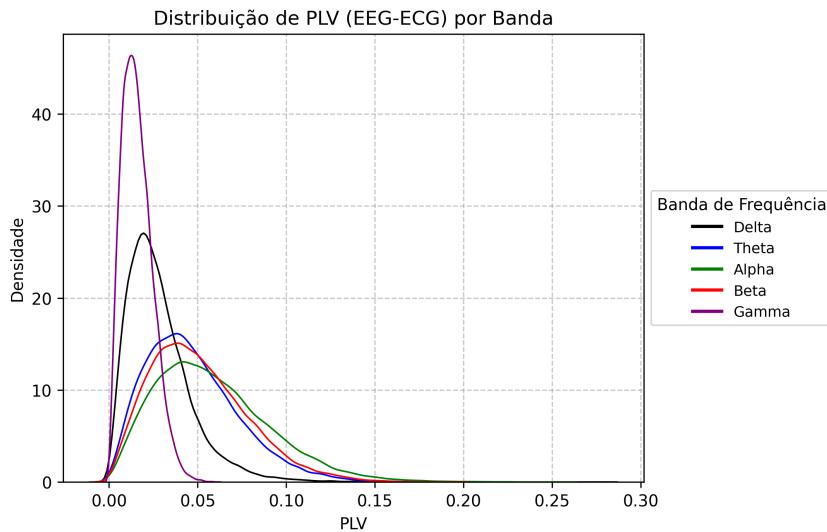


Figura 25 – Distribuição de PLV (EEG-ECG) por banda. Nota-se grande aglomeração de valores próximos de zero, revelando baixa coerência de fase iso-frequencial entre o sinal cardíaco e as oscilações cerebrais na maioria dos pares.

“puras” de conectividade, servindo de ponto de partida para as comparações entre condições (Pós e Pré) apresentadas na próxima subseção.

7.1.2 Distribuição das Diferenças (Median Diff)

Para testar o efeito da estimulação (*cathodic* versus *sham*), os valores medidos após a intervenção (pós) foram comparados com os valores obtidos antes da intervenção (pré). Assim, a métrica de diferença (`median_diff`) é calculada subtraindo-se o valor pré do valor pós (por exemplo, pós-sham – pré-sham). Essa operação visa isolar o efeito da

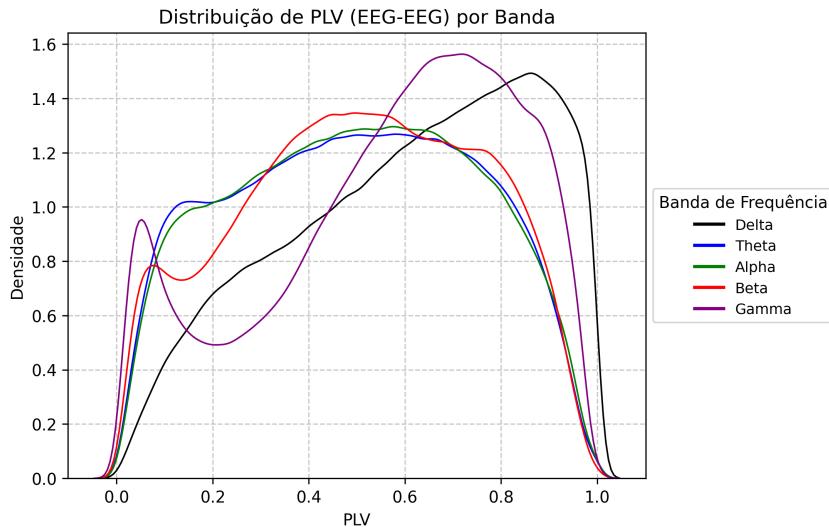


Figura 26 – Distribuição de PLV (EEG-EEG) por banda. Alguns valores atingem níveis elevados (acima de 0.5), indicando que certos pares de canais EEG podem apresentar forte *phase locking* em determinadas faixas de frequência, especialmente em gamma.

intervenção, eliminando variações comuns que possam estar presentes independentemente da estimulação.

As distribuições das diferenças foram, então, avaliadas por meio de histogramas com *Kernel Density Estimation* (KDE) para as métricas de PLI e CF-PLM, conforme ilustrado nas figuras abaixo:

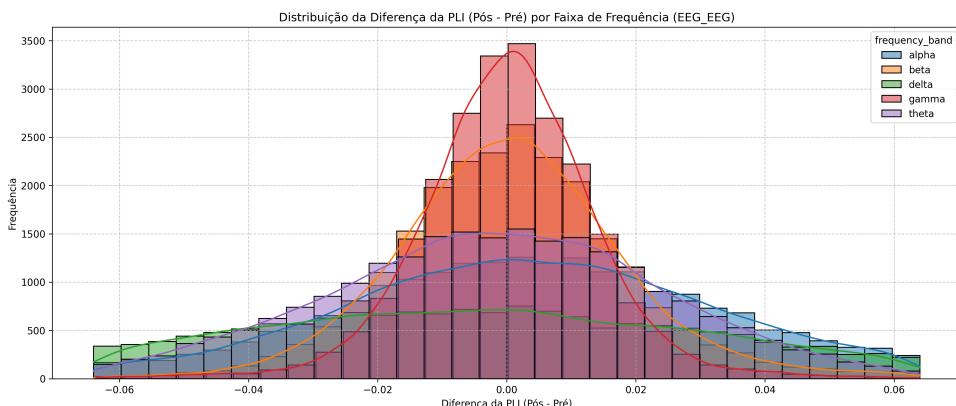


Figura 27 – Distribuição da diferença da PLI (Pós – Pré) por faixa de frequência para EEG-EEG.

7.1.2.1 Exemplo Individual por Métrica e Banda

Para ilustrar de forma mais específica como essas distribuições se comportam em um caso individual, a Figura 35 exibe a distribuição da diferença da métrica `median_cf_plm_diff` (Pós – Pré) para o atleta 4, na banda *alpha*, em pares EEG-ECG. Já a Figura 36 apresenta

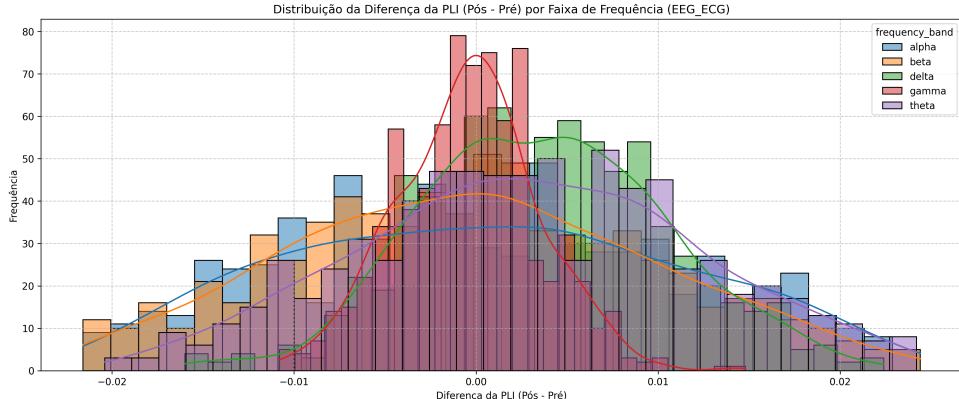


Figura 28 – Distribuição da diferença da PLI (Pós – Pré) por faixa de frequência para EEG-ECG.

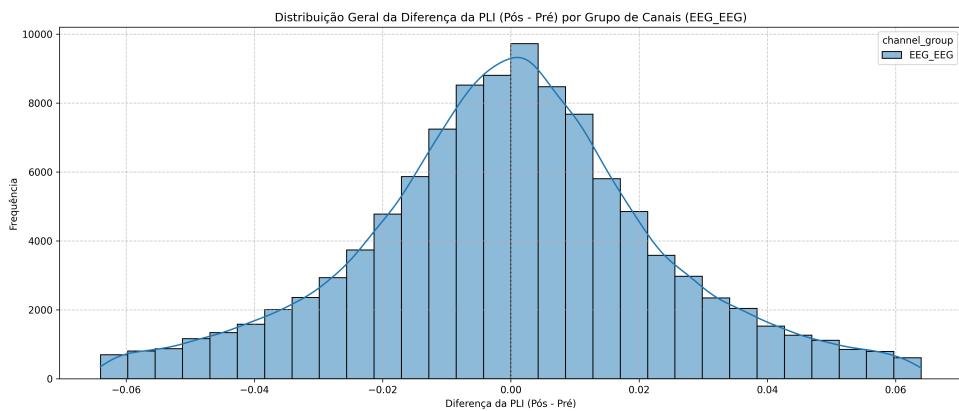


Figura 29 – Distribuição geral da diferença da PLI (Pós – Pré) por grupo de canais (EEG-EEG).

a distribuição da diferença da `median_pli_diff` para o mesmo atleta 4 e banda alpha, porém em pares EEG-EEG.

Essas figuras exemplificam como as diferenças entre as condições *cathodic* (azul) e *sham* (vermelho) podem se sobrepor ou divergir. Em alguns casos, a curva KDE de

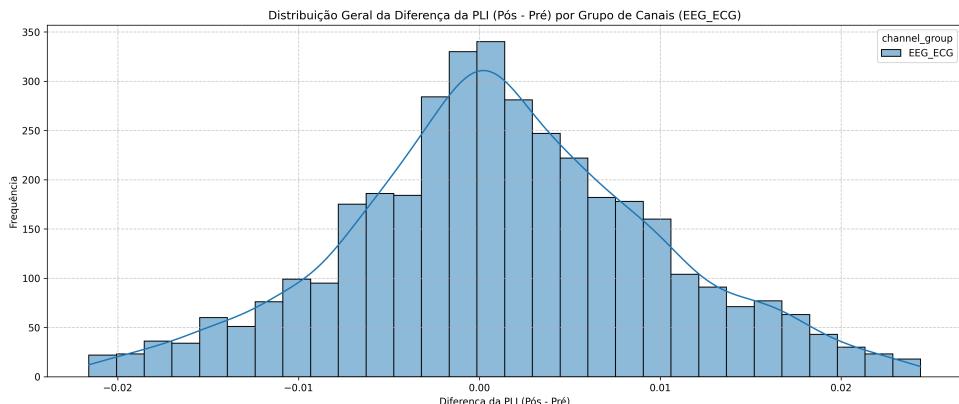


Figura 30 – Distribuição geral da diferença da PLI (Pós – Pré) por grupo de canais (EEG-ECG).

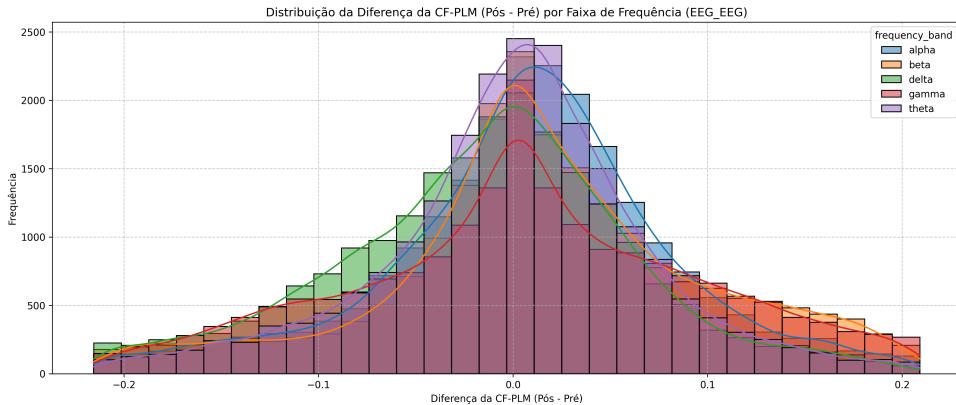


Figura 31 – Distribuição da diferença da CF-PLM (Pós – Pré) por faixa de frequência para EEG-EEG.

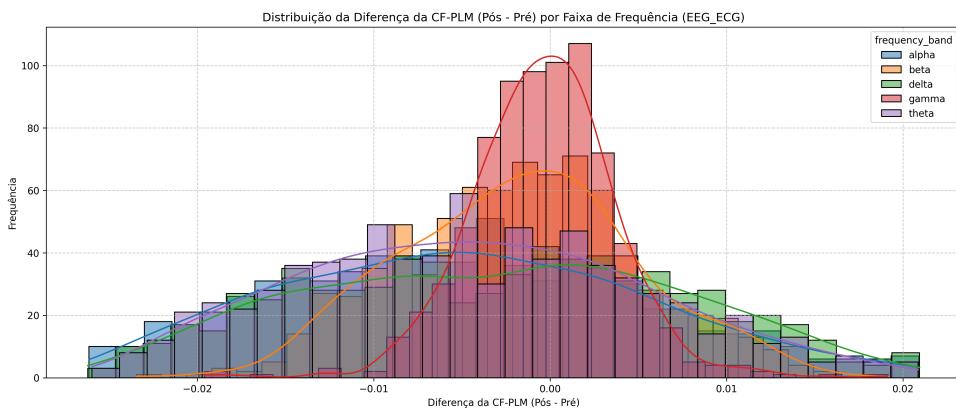


Figura 32 – Distribuição da diferença da CF-PLM (Pós – Pré) por faixa de frequência para EEG-ECG.

uma condição pode deslocar-se à direita (indicando um aumento na métrica após a estimulação) ou à esquerda (indicando redução), enquanto em outros a sobreposição é substancial, sugerindo pouca mudança entre as condições. Esse tipo de análise individual é útil para verificar a variabilidade intra-sujeito e entender melhor se os efeitos observados

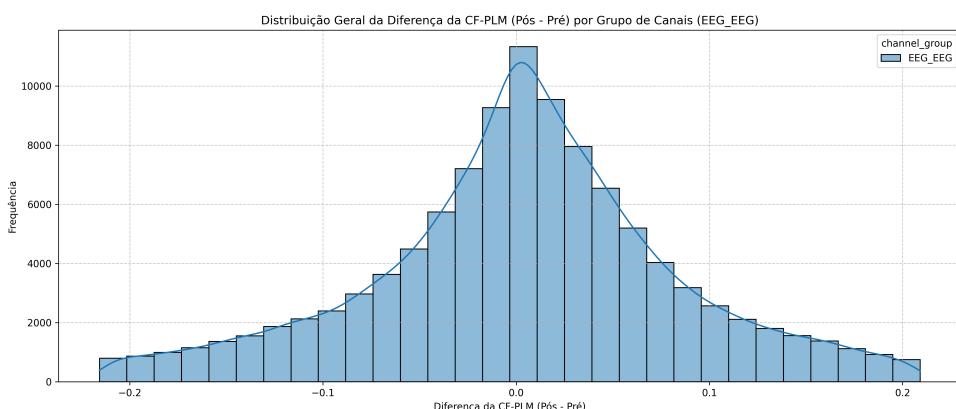


Figura 33 – Distribuição geral da diferença da CF-PLM (Pós – Pré) por grupo de canais (EEG-EEG).

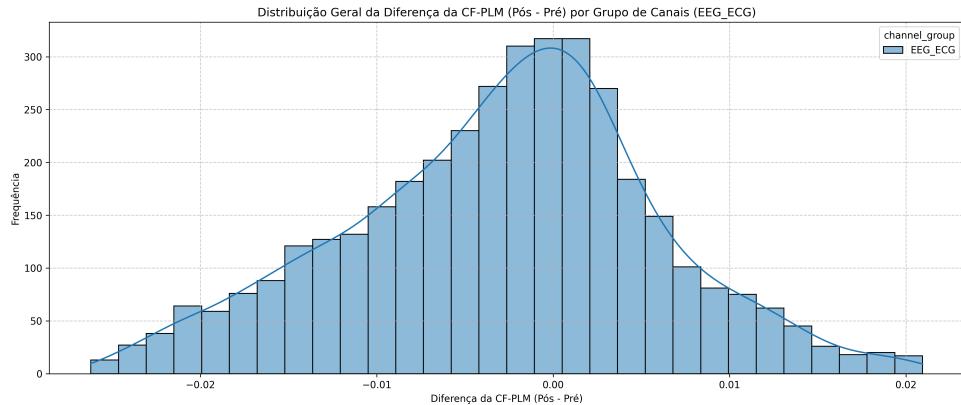


Figura 34 – Distribuição geral da diferença da CF-PLM (Pós – Pré) por grupo de canais (EEG-ECG).

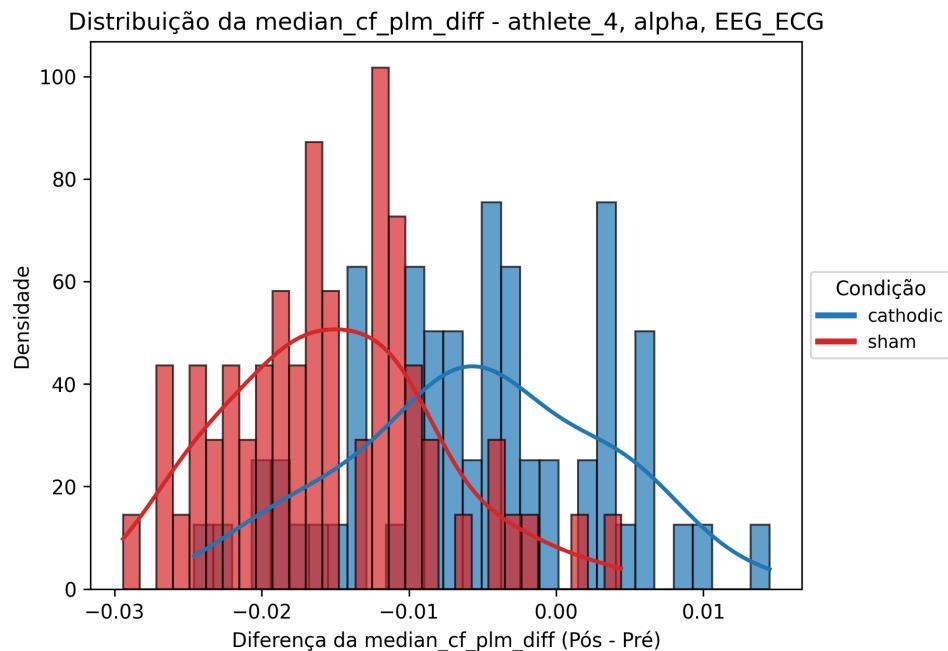


Figura 35 – Distribuição da `median_cf_plm_diff` (Pós – Pré) para o atleta 4, banda alpha, em pares EEG-ECG.

são consistentes ou pontuais.

7.2 Verificação de Normalidade e Escolha do Teste Estatístico

Para definir se o teste estatístico a ser empregado é paramétrico ou não-paramétrico, é necessário verificar a normalidade das distribuições de interesse. Nesse contexto, testes como o de *Shapiro-Wilk* ou *Kolmogorov-Smirnov* podem ser aplicados para cada grupo de canais e faixa de frequência, tanto para a PLI quanto para a CF-PLM.

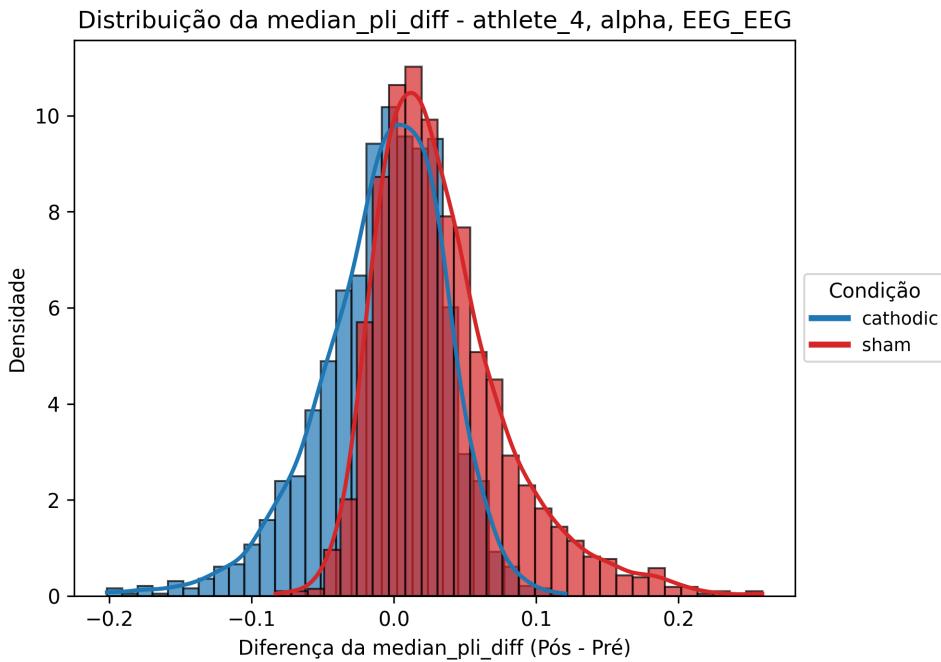


Figura 36 – Distribuição da `median_pli_diff` (Pós – Pré) para o atleta 4, banda alpha, em pares EEG-EEG.

7.2.0.0.1 Considerações:

- **Tamanho amostral:** dada a quantidade relativamente grande de observações (após agregação), mesmo pequenas diferenças em relação à distribuição normal podem resultar em rejeição estatística da hipótese de normalidade.
- **Forma das distribuições:** visualmente, muitas distribuições parecem aproximadamente simétricas e unimodais. Ainda assim, pequenas assimetrias ou caudas mais alongadas podem exigir cautela na adoção de testes paramétricos.
- **Interpretação:** se a maioria das distribuições não satisfizer os critérios de normalidade (p. ex. $p\text{-valor} < 0.05$), a análise inferencial subsequente pode se apoiar em testes não-paramétricos (por exemplo, *Wilcoxon signed-rank* ou *Mann-Whitney*).

7.2.0.0.2 Próximos Passos:

- Realizar os testes de normalidade (Shapiro-Wilk e/ou Kolmogorov-Smirnov) para cada combinação relevante de (*faixa de frequência, grupo de canais*).
- Avaliar as medidas de assimetria (*skewness*) e curtose (*kurtosis*) para confirmar a adequação de testes paramétricos ou justificar o uso de métodos não-paramétricos.

Com base nessa análise preliminar, será possível conduzir as etapas seguintes de inferência estatística, considerando as particularidades de cada métrica (PLI e CF-PLM) e garantindo uma avaliação mais robusta das diferenças entre condições.

7.3 Testes de Normalidade e Decisão sobre o Tipo de Teste Estatístico

A escolha entre testes paramétricos e não paramétricos depende fundamentalmente da distribuição dos dados. Para as métricas de conectividade (median_plv_diff, median_pli_diff e median_cf_plm_diff) agrupadas nos grupos EEG_EEG e EEG_ECG, aplicamos uma série de testes de normalidade, a saber: Shapiro-Wilk, Kolmogorov-Smirnov, Anderson-Darling, D'Agostino's K-squared, Jarque-Bera e Lilliefors. Além disso, para atenuar o efeito de valores extremos, os testes foram realizados tanto com os dados originais quanto após a remoção de outliers utilizando o método do *Interquartile Range* (IQR).

7.3.0.0.1 Motivações e Procedimentos:

- **Objetivo:** Verificar se as distribuições das diferenças (Pós – Pré) seguem uma forma aproximadamente gaussiana, o que permitiria o uso de testes paramétricos.
- **Procedimento:**
 - Os dados foram agrupados por channel_group (EEG_EEG e EEG_ECG) e para cada métrica.
 - Foram aplicados os testes de normalidade com e sem outliers, permitindo avaliar o efeito destes na distribuição.

7.3.0.0.2 Principais Resultados:

- **Grupo EEG_EEG:**
 - Para median_plv_diff, todos os testes (Shapiro-Wilk, Kolmogorov-Smirnov, Anderson-Darling, D'Agostino, Jarque-Bera e Lilliefors) apresentaram p-valores inferiores a 0,001, rejeitando a hipótese de normalidade, mesmo após a remoção de aproximadamente 9,44% dos dados como outliers.
 - Similarmente, para median_pli_diff e median_cf_plm_diff, os testes indicaram desvios significativos da normalidade (p-valores muito baixos), mesmo após a filtragem de outliers (10,66% e 10,65% dos dados, respectivamente).
- **Grupo EEG_ECG:**

- Embora a remoção de outliers tenha melhorado levemente a distribuição de `median_plv_diff` (com alguns testes chegando a p-valores marginalmente aceitáveis), para `median_pli_diff` e `median_cf_plm_diff` os testes continuaram a rejeitar a normalidade (p-valores próximos de zero na maioria dos casos).

7.3.0.0.3 Interpretação e Decisão Metodológica:

Os resultados dos testes de normalidade demonstram que, em sua maioria, as distribuições das diferenças nas métricas de conectividade não se comportam de maneira normal, mesmo após a remoção de outliers. Essa violação do pressuposto de normalidade indica que a aplicação de testes paramétricos (que assumem uma distribuição gaussiana dos dados) poderia levar a inferências incorretas. Portanto, optamos por utilizar testes não paramétricos para as análises estatísticas subsequentes, garantindo robustez e validade às conclusões sem a necessidade de assumir normalidade dos dados.

8 Análise Estatística Não Paramétrica

Tendo em vista que os dados das métricas de conectividade (diferença entre Pós e Pré) não se comportam de maneira normal (ver Capítulo 7), optamos por empregar testes estatísticos não paramétricos para comparar as condições de estimulação (*cathodic* versus *sham*). Essa escolha evita pressupostos inadequados sobre a distribuição dos dados e confere maior robustez às inferências.

Nesta etapa, foram aplicados os seguintes testes:

- **Mann-Whitney U:** Teste para amostras independentes, comparando as condições para cada faixa de frequência e grupo de canais. O efeito foi estimado pela fórmula:

$$\text{effect size} = \frac{2 \cdot \text{stat}}{n_{\text{cathodic}} \cdot n_{\text{sham}}} - 1.$$

- **Wilcoxon:** Teste para amostras pareadas, no qual os dados foram emparelhados por atleta, par de canais e faixa de frequência, possibilitando uma comparação intraindividual entre as condições.
- **Kruskal-Wallis:** Teste para múltiplos grupos, empregado para comparar as condições quando os dados foram agrupados por faixa de frequência, com o tamanho do efeito estimado pela razão entre a estatística do teste e o número total de observações menos um.

Os testes foram realizados separadamente para cada uma das métricas de conectividade:

- `median_plv_diff`
- `median_pli_diff`
- `median_cf_plm_diff`

e para os dois grupos de canais: `EEG_EEG` e `EEG_ECG`. Ressalta-se que, embora o código inclua procedimentos para remoção de dados nulos, na prática esses valores não estão presentes, servindo apenas para tratamento de exceções.

8.1 Resultados dos Testes

8.1.1 Métricas para median_plv_diff

8.1.1.0.1 Grupo EEG_EEG:

- **Mann-Whitney U:** As faixas *alpha*, *beta*, *delta*, *gamma* e *theta* apresentaram p-valores extremamente baixos (por exemplo, $p < 10^{-29}$ para *alpha* e $p < 10^{-132}$ para *gamma*), indicando diferenças estatisticamente significativas entre as condições. Os tamanhos de efeito variaram, com valores próximos a -0.088 e 0.191.
- **Wilcoxon:** Os testes pareados mostraram p-valores próximos de zero para todas as faixas, com tamanhos de efeito em torno de 0.393.
- **Kruskal-Wallis:** Também foram encontradas diferenças significativas em todas as faixas, com tamanhos de efeito entre 0.0058 e 0.0273.

8.1.1.0.2 Grupo EEG_ECG:

- **Mann-Whitney U:** Foram significativas as faixas *alpha*, *beta* e *theta* (p-valores menores que 0.001) e a *gamma* apresentou um p-valor marginal ($p \approx 0.041$), enquanto a faixa *delta* não alcançou significância ($p \approx 0.148$).
- **Wilcoxon:** Os testes demonstraram diferenças robustas, com p-valores extremamente baixos e tamanhos de efeito de aproximadamente 0.381.
- **Kruskal-Wallis:** Os resultados foram significativos para *alpha*, *beta* e *theta*, mas não para *delta* e *gamma*.

8.1.2 Métricas para median_pli_diff

8.1.2.0.1 Grupo EEG_EEG:

- **Mann-Whitney U:** As faixas *alpha*, *delta*, *gamma* e *theta* apresentaram diferenças significativas (p-valores < 0.001), enquanto a faixa *beta* teve um resultado marginal ($p \approx 0.051$).
- **Wilcoxon:** Os testes pareados indicaram significância robusta em todas as faixas, com tamanho de efeito em torno de 0.477.
- **Kruskal-Wallis:** As faixas *alpha*, *delta*, *gamma* e *theta* foram significativamente diferentes, com *beta* sendo marginalmente não significativo.

8.1.2.0.2 Grupo EEG_ECG:

- **Mann-Whitney U:** Apenas as faixas *delta* e *gamma* mostraram diferenças significativas, enquanto *alpha* e *beta* não atingiram significância.
- **Wilcoxon:** Todos os testes foram altamente significativos, com tamanhos de efeito próximos a 0.441.
- **Kruskal-Wallis:** Apenas *alpha*, *delta* e *gamma* foram significativas; as faixas *beta* e *theta* não apresentaram diferenças estatísticas.

8.1.3 Métricas para median_cf_plm_diff

8.1.3.0.1 Grupo EEG_EEG:

- **Mann-Whitney U:** Todas as faixas foram significativamente diferentes entre as condições (p-valores muito baixos), com tamanhos de efeito variando de -0.062 a 0.274.
- **Wilcoxon:** Resultados extremamente significativos foram observados para todas as faixas, com tamanho de efeito em torno de 0.355.
- **Kruskal-Wallis:** Todas as faixas apresentaram diferenças significativas, com tamanhos de efeito entre 0.0029 e 0.0563.

8.1.3.0.2 Grupo EEG_ECG:

- **Mann-Whitney U:** Foram significativas as faixas *alpha*, *beta* e *delta* (p-valores menores que 0.05), enquanto *gamma* e *theta* não apresentaram significância.
- **Wilcoxon:** Todos os testes resultaram em p-valores extremamente baixos, com tamanhos de efeito de aproximadamente 0.358.
- **Kruskal-Wallis:** As faixas *alpha*, *beta* e *gamma* foram significativas, mas *delta* e *theta* não apresentaram diferenças estatísticas.

8.2 Discussão e Justificativa dos Métodos

Dado que os testes de normalidade indicaram violações significativas do pressuposto de normalidade para as três métricas analisadas, a utilização de testes não paramétricos se mostrou necessária. Tais métodos não dependem de pressupostos sobre a distribuição dos dados, oferecendo uma análise mais robusta e confiável. Além disso, a aplicação de múltiplos

testes (Mann-Whitney U, Wilcoxon e Kruskal-Wallis) permitiu uma avaliação abrangente das diferenças entre as condições `cathodic` e `sham`, considerando tanto comparações entre grupos independentes quanto análises pareadas intraindividuais.

Os resultados indicam que, para a maioria das faixas de frequência e para as métricas `median_plv_diff` e `median_cf_plm_diff`, existem diferenças estatisticamente significativas entre as condições, reforçando a importância da modulação induzida pela estimulação. Por sua vez, os achados para `median_pli_diff` foram menos consistentes, variando conforme o teste e a faixa considerada.

Em suma, a escolha dos testes não paramétricos foi justificada pela distribuição não normal dos dados, e os resultados obtidos fornecem evidências sólidas de diferenças na sincronização de fase entre as condições experimentais, reforçando os efeitos da estimulação no contexto das análises de conectividade.

8.3 Detecção de Outliers, Análise Bootstrap e Correções para Comparações Múltiplas

Para aprimorar a qualidade dos dados e reduzir o impacto de pontos atípicos nas análises subsequentes, executamos uma etapa de detecção e remoção de outliers utilizando o método ECOD (Empirical Cumulative Distribution-based Outlier Detection). Esse método é especialmente adequado para nosso conjunto de dados por sua natureza não paramétrica, que permite identificar anomalias sem pressupor uma distribuição específica. O ECOD estima a função de distribuição cumulativa empírica em cada dimensão, identificando como outliers os pontos que se desviam significativamente do comportamento esperado. Estudos demonstram que essa abordagem supera diversas técnicas de detecção de outliers em termos de acurácia e eficiência (??).

Aplicamos o ECOD considerando as métricas `median_plv_diff`, `median_pli_diff` e `median_cf_plm_diff`. Inicialmente, o dataset continha 122915 entradas; após a aplicação do ECOD, identificamos 6146 outliers, o que corresponde a aproximadamente 5.00% dos dados. A remoção desses outliers resultou em um dataset com 116769 linhas, melhorando a confiabilidade das análises posteriores.

Posteriormente, implementamos um robusto pipeline de análise por meio de bootstrap acelerado por GPU, utilizando CuPy para calcular intervalos de confiança BCa (Bias-Corrected and Accelerated). Esse método é particularmente robusto, pois ajusta tanto o viés quanto a aceleração da distribuição bootstrap, permitindo capturar as assimetrias e a presença de outliers nos dados. Essa abordagem, embora computacionalmente custosa, é amplamente considerada uma das mais robustas para a estimativa de intervalos de confiança em situações em que os pressupostos de normalidade não são atendidos.

Além disso, o método BCa foi escolhido em detrimento de outros métodos de intervalo de confiança por sua capacidade de corrigir a distorção na distribuição da estatística estimada.

A análise é realizada agrupando os dados por combinações de *channel pair*, *frequency band* e *channel group* (os quais são mutuamente exclusivos, como EEG_EEG e EEG_ECG). Essa estratégia permite comparar diferenças entre as condições dentro de cada subgrupo. Para mitigar o risco de falsos positivos decorrentes do elevado número de comparações (estimado em 11346 testes, considerando 1891 channel pairs e 6 faixas de frequência), foram aplicadas correções para comparações múltiplas. Entre os métodos de correção, o Bonferroni se destaca por sua extrema rigidez e conservadorismo, sendo considerado o mais robusto, principalmente em contextos com um elevado número de testes. Embora métodos como Holm e FDR-BH também tenham sido calculados e estejam disponíveis para comparação, o Bonferroni é adotado como referência primária na decisão de significância, visto que o threshold ajustado (aproximadamente 0.00000441) minimiza o risco de erros do tipo I.

Além disso, em nosso pipeline também foram computados tamanhos de efeito utilizando diversas métricas, tais como:

- **Cohen's d e Hedges' g:** que quantificam a magnitude da diferença entre as condições em termos de desvios-padrão;
- **Rank-Biserial Correlation (RBC):** derivado do teste de Wilcoxon, que fornece uma interpretação robusta baseada em postos.

Essas métricas complementares permitem uma avaliação abrangente do efeito da estimulação e possibilitam a comparação dos resultados com os intervalos de confiança BCa e os valores-p corrigidos pelo método Bonferroni. Na tabela de resultados em anexo, os leitores encontrarão também as correções de Holm e FDR-BH, bem como os tamanhos de efeito calculados, permitindo uma comparação completa dos diferentes métodos.

Em resumo, nossa abordagem comprehende as seguintes etapas:

1. **Detecção de Outliers:** Utilizamos o ECOD para identificar e remover aproximadamente 5% dos dados que se comportavam como anomalias, garantindo a robustez dos dados para análise.
2. **Análise Bootstrap com GPU:** Implementamos o cálculo de intervalos de confiança BCa, estimando viés, erro padrão e tamanhos de efeito por meio de reamostragem (bootstrap) acelerada por GPU, garantindo a precisão dos intervalos mesmo com distribuições assimétricas.
3. **Testes Não Paramétricos e Correção para Comparações Múltiplas:** Aplicamos o teste de Wilcoxon (para dados emparelhados) e outras análises não paramétricas.

tricas, e corrigimos os valores-p utilizando métodos conservadores, com ênfase no Bonferroni, para reduzir o risco de erros do tipo I.

Os resultados deste processamento serão apresentados em detalhes nos anexos, permitindo a comparação dos resultados obtidos com e sem a remoção de outliers, e a análise dos diferentes tamanhos de efeito e métodos de correção.

8.4 Distribuição de Tamanhos de Efeito e p-valores

Nesta etapa, examinamos a distribuição das estimativas de tamanho de efeito (*Cohen's d*, *Hedges' g* e *Wilcoxon RBC*) e dos valores-p (brutos e corrigidos por Bonferroni) para as análises de PLI (EEG-EEG) e CF-PLM (EEG-ECG), considerando cenários com e sem outliers. A Figura 37 ilustra, em quatro subfiguras, como essas métricas se distribuem ao longo dos pares de canal e faixas de frequência analisados.

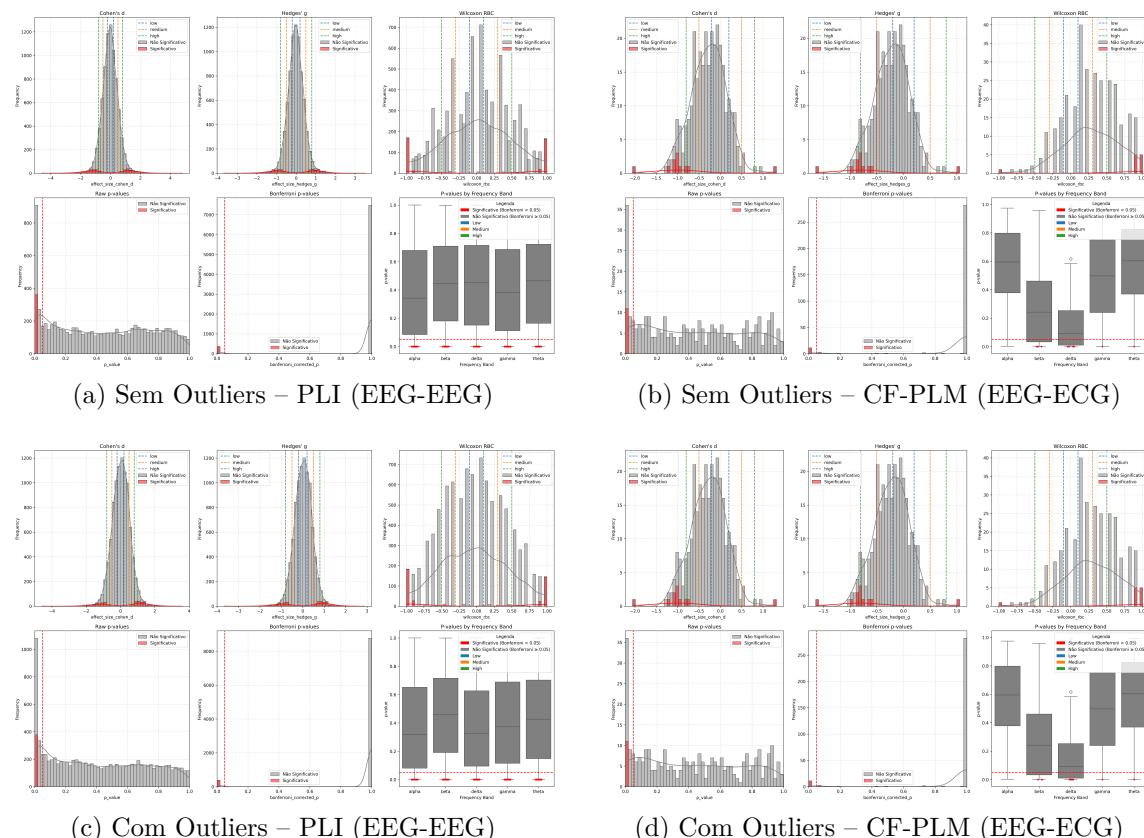


Figura 37 – Distribuição das métricas de tamanho de efeito (*Cohen's d*, *Hedges' g* e *Wilcoxon RBC*) e dos valores-p (brutos e corrigidos por Bonferroni) para PLI (EEG-EEG) e CF-PLM (EEG-ECG), em cenários com e sem outliers. O *Wilcoxon RBC* e o p-valor corrigido por Bonferroni (vertical tracejada vermelha em $p = 0.05$) são enfatizados como as métricas mais robustas para, respectivamente, o tamanho de efeito e a significância estatística.

8.4.1 Distribuição dos Tamanhos de Efeito

8.4.1.0.1 Cohen's d e Hedges' g

- A maior parte dos valores concentra-se em torno de zero, indicando que, para a maioria dos pares, as diferenças entre *cathodic* e *sham* são pequenas ou não significativas.
- Valores significativos (barras vermelhas nos histogramas) tendem a se afastar de zero, sinalizando diferenças mais acentuadas. Por exemplo, *Cohen's d* ou *Hedges' g* acima de 0.5 (ou abaixo de -0.5) sugere um efeito moderado, e acima de 0.8 (ou abaixo de -0.8) indica um efeito alto.
- *Hedges' g* difere de *Cohen's d* por aplicar uma correção para tamanhos amostrais pequenos, mas ambas exibem comportamentos semelhantes nos histogramas.

8.4.1.0.2 Wilcoxon RBC (Rank-Biserial Correlation)

- O *Wilcoxon RBC* é derivado do teste não paramétrico de Wilcoxon, refletindo a correlação de postos entre as condições (tipicamente variando de -1 a +1).
- Por não exigir pressupostos de normalidade, o RBC mostra-se mais robusto ao lidar com dados heterogêneos e eventuais outliers.
- Valores acima de 0.3 ou abaixo de -0.3 sugerem efeito moderado; acima de 0.5 (ou abaixo de -0.5) indicam efeito alto. Quando se aproxima de ± 1 , as condições diferem de forma quase absoluta.
- Devido a essa robustez, o RBC será nosso principal indicador de tamanho de efeito nas análises subsequentes.

8.4.2 Distribuição de p-valores (Brutos e Corrigidos)

- Os histogramas de valores-p brutos exibem forte concentração em torno de 1 (resultados não significativos) e uma cauda próxima de 0 (potenciais resultados significativos).
- Após a correção de Bonferroni (marcada pela linha vertical tracejada em $p = 0.05$), muitos valores que eram marginalmente significativos são deslocados para a região de não significância, evidenciando o caráter conservador desta correção.
- Em virtude do elevado número de comparações, a adoção de um método rigoroso como o Bonferroni minimiza a probabilidade de falsos positivos. Por esse motivo, utilizamos o p-valor corrigido por Bonferroni como critério principal de significância.

8.4.3 Comparação Entre Cenários (Com e Sem Outliers)

- **Diferenças Mínimas:** Em geral, a remoção de outliers reduz ligeiramente o número de casos significativos, mas não altera substancialmente a distribuição geral dos tamanhos de efeito e dos valores-p.
- **PLI (EEG-EEG):** Apresenta maior número de efeitos significativos (por exemplo, 378 vs. 363), enquanto o *CF-PLM (EEG-ECG)* se mostra mais pontual (apenas 11 casos) em ambos os cenários, evidenciando que a sincronia cross-frequency entre EEG e ECG é mais específica.
- **Robustez do RBC e do Bonferroni:** Independentemente de manter ou remover outliers, as comparações que exibem *Wilcoxon RBC* elevado e valores-p corrigidos abaixo de 0.05 são consideradas efeitos fortes e confiáveis, reforçando a relevância dessas duas métricas em nossas conclusões.

Em síntese, os histogramas de *Wilcoxon RBC* (tamanho de efeito) e p-valores corrigidos por Bonferroni (significância estatística) demonstram claramente quais pares de canais se destacam por apresentarem diferenças robustas entre *cathodic* e *sham*. Embora *Cohen's d* e *Hedges' g* também sejam úteis para quantificar a magnitude do efeito, nossa análise dá ênfase ao RBC por ser não paramétrico e resiliente à heterogeneidade dos dados. Assim, estes resultados embasam as análises topográficas e de rede apresentadas nas seções seguintes.

8.4.4 Comparação Entre Cenários (Com e Sem Outliers)

- **Redução de Casos Significativos:** Para o PLI em *EEG_EEG*, por exemplo, temos 378 casos significantes ao manter os outliers e 363 após removê-los. A remoção de outliers atenua ligeiramente os valores extremos, reduzindo o número de pares que atingem significância, mas não altera drasticamente a distribuição geral.
- **Magnitude dos Efeitos:** Mesmo sem outliers, ainda há uma parcela considerável de pares exibindo *Cohen's d* (ou *Hedges' g*) em torno de 0.5 a 0.8 ou RBC acima de 0.3, sugerindo efeitos moderados a altos em alguns canais ou faixas de frequência.
- **CF-PLM em EEG_ECG:** Observa-se um número bem menor de casos significativos (11 em ambos os cenários), o que indica que a sincronia entre EEG e ECG (medida pelo CF-PLM) é mais pontual e dependente de condições específicas, em contraste com a PLI *EEG_EEG*, que registra maior número de efeitos estatisticamente relevantes.

8.4.5 Conclusões Principais

- A maior parte dos dados concentra-se em torno de zero para todas as métricas, refletindo pequenas diferenças entre as condições, o que é coerente com métodos robustos de correção múltipla (p. ex. Bonferroni) e o grande número de comparações.
- Quando há significância estatística, os tamanhos de efeito se afastam notavelmente de zero (*Cohen's d*, *Hedges' g* ou RBC), sugerindo diferenças substanciais e possivelmente relevantes do ponto de vista neurofisiológico.
- O *Wilcoxon RBC* se mostra particularmente robusto para capturar a direção e a magnitude das diferenças sem pressupor normalidade, razão pela qual será enfatizado nas próximas análises topográficas e de grafos de conectividade.

Assim, a análise dos histogramas de tamanho de efeito e valores-p fornece um panorama inicial: embora haja muitos casos não significativos, uma fração não desprezível apresenta efeitos moderados ou altos e valores-p corrigidos abaixo do limiar. Tais resultados embasam investigações posteriores, que buscarão caracterizar a localização e as faixas de frequência onde a *neuromodulação* exerce impacto mais pronunciado.

8.5 Análise de Rede para PLI (EEG-EEG)

Nesta seção, analisamos as redes de conexões significativas obtidas pela métrica PLI para pares EEG-EEG, segmentadas por bandas de frequência, considerando os cenários com e sem outliers. Em cada grafo, cada nó representa um canal EEG e o número exibido ao lado indica a quantidade de conexões significativas envolvendo aquele canal. As linhas conectando os nós correspondem aos pares significativos, onde as linhas vermelhas indicam valores de *Wilcoxon RBC* tendendo a +1 (indicando conexões com efeitos extremamente fortes), enquanto linhas em azul indicariam valores próximos a -1 (não observados neste estudo).

A seguir, apresentamos os gráficos para cada banda de frequência.

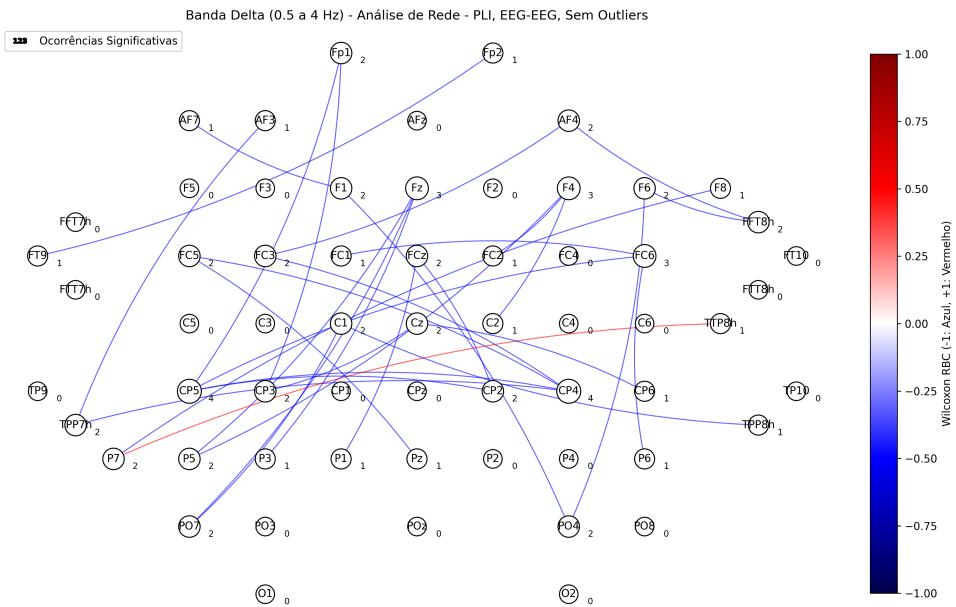


Figura 38 – Rede de conexões significativas na banda Delta (0.5–4 Hz) para PLI (EEG-EEG) sem outliers. A rede é esparsa, com poucas conexões, o que sugere que a sincronização nessa faixa é limitada e pontual.

8.5.1 Cenário Sem Outliers

8.5.1.1 Banda Delta (0.5–4 Hz)

8.5.1.2 Banda Theta (4–8 Hz)

8.5.1.3 Banda Alpha (8–13 Hz)

8.5.1.4 Banda Beta (13–30 Hz)

8.5.1.5 Banda Gamma (30–60 Hz)

8.5.2 Cenário Com Outliers

8.5.2.1 Banda Delta (0.5–4 Hz)

8.5.2.2 Banda Theta (4–8 Hz)

8.5.2.3 Banda Alpha (8–13 Hz)

8.5.2.4 Banda Beta (13–30 Hz)

8.5.2.5 Banda Gamma (30–60 Hz)

8.5.3 Análise Comparativa dos Cenários

A comparação entre os cenários com e sem outliers para a métrica PLI em pares EEG-EEG evidencia que:

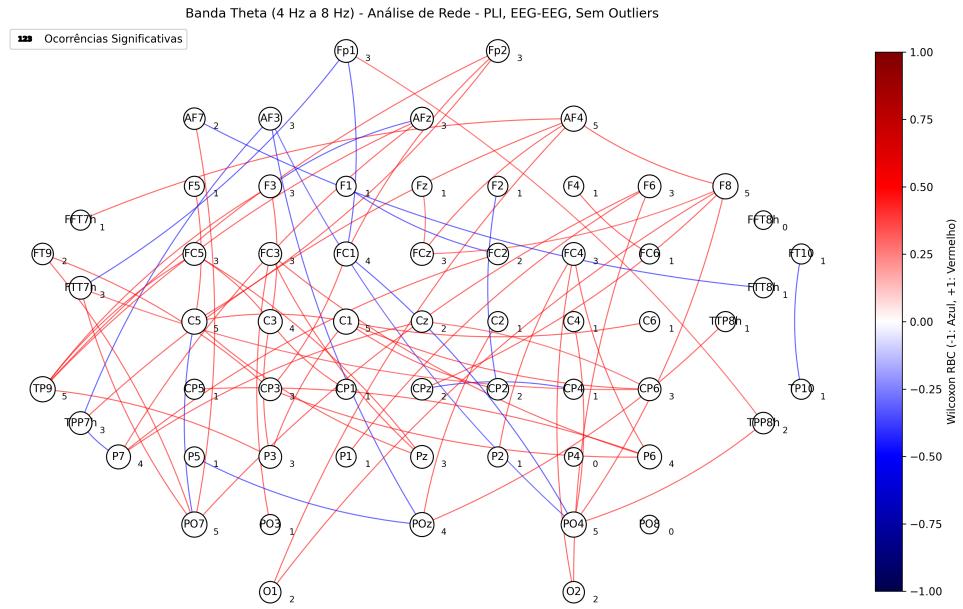


Figura 39 – Rede de conexões significativas na banda Theta (4–8 Hz) para PLI (EEG-EEG) sem outliers. A conectividade é moderada, com alguns canais exibindo um número elevado de conexões, indicando sua importância na sincronização nesta faixa.

- **Topologia Geral Inalterada:** A estrutura das redes – identificada por canais com maior centralidade e o padrão de conexões – permanece praticamente a mesma em ambos os cenários.
- **Número de Conexões:** Há uma ligeira redução no número de conexões significativas quando os outliers são removidos (por exemplo, 378 casos com outliers versus 363 sem outliers), o que é esperado, pois a remoção de valores extremos pode atenuar alguns efeitos marginais.
- **Robustez dos Efeitos:** Os pares com *Wilcoxon RBC* de +1, indicados pelas linhas vermelhas, persistem em ambos os cenários, reforçando a confiabilidade dos efeitos encontrados.

Essas observações corroboram a robustez da análise PLI, demonstrando que, embora a remoção de outliers reduza ligeiramente o número de conexões, a topologia e a intensidade dos efeitos permanecem consistentes.

8.6 Análise de Rede para CF-PLM (EEG-ECG, Cross-frequency)

Nesta seção, avaliamos as redes de conectividade entre sinais de EEG e ECG obtidas pela métrica CF-PLM, que quantifica a sincronização entre frequências distintas (cross-frequency). Em cada gráfico, os nós representam os canais (tanto os canais EEG quanto o canal ECG) e o número exibido ao lado de cada nó indica a quantidade de

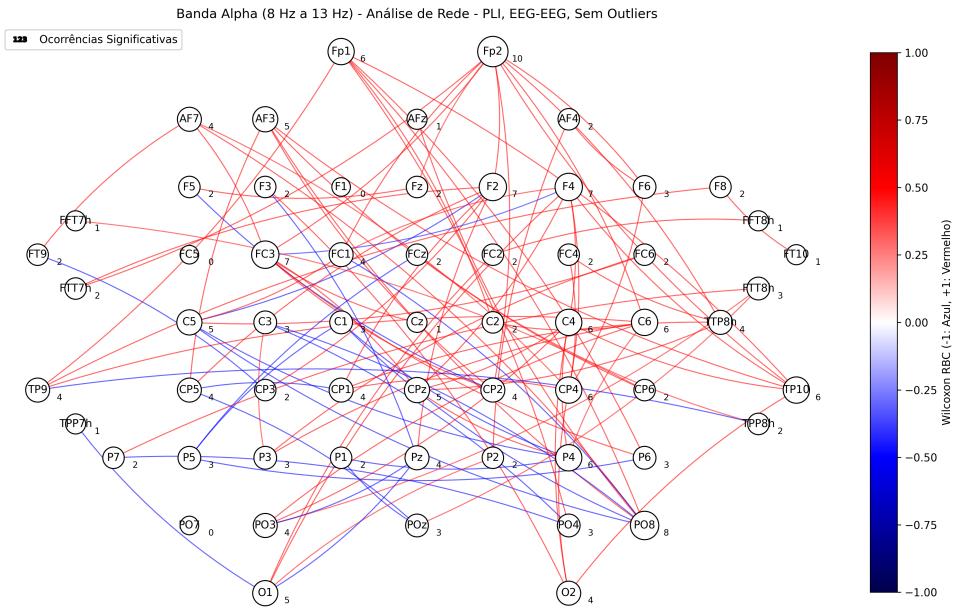


Figura 40 – Rede de conexões significativas na banda Alpha (8–13 Hz) para PLI (EEG-EEG) sem outliers. Observa-se uma rede densa com um núcleo central de canais altamente conectados, sugerindo uma forte sincronização nesta banda.

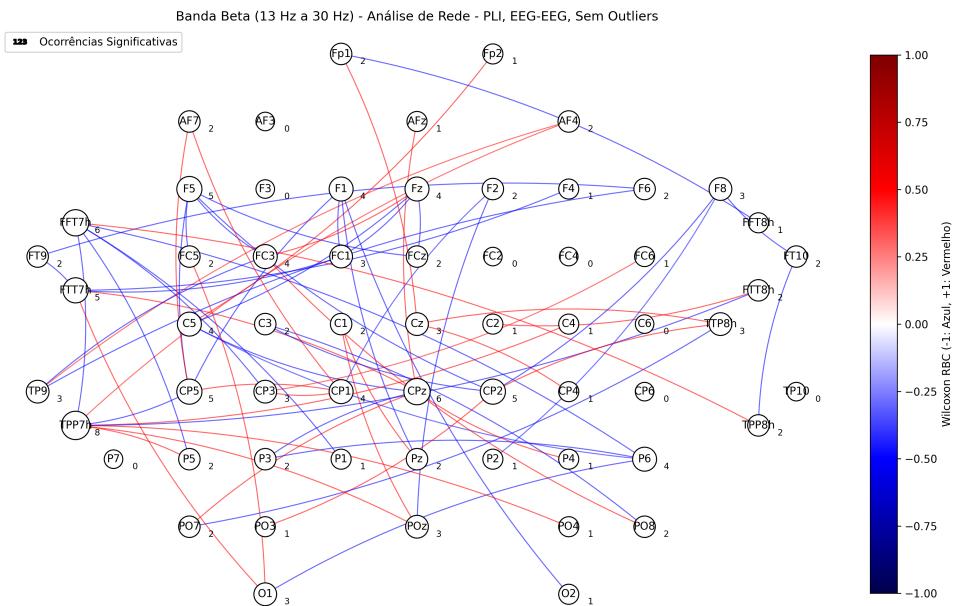


Figura 41 – Rede de conexões significativas na banda Beta (13–30 Hz) para PLI (EEG-EEG) sem outliers. A rede apresenta conectividade intermediária, com uma distribuição relativamente homogênea das conexões entre os canais.

conexões significativas envolvendo aquele canal. As linhas que conectam os nós representam os pares significativos; neste estudo, os casos significativos exibem *Wilcoxon RBC* de +1, o que denota efeitos extremamente robustos (não foram observados casos com valores próximos a -1).

Observamos que, para CF-PLM, o número total de pares significativos é idêntico

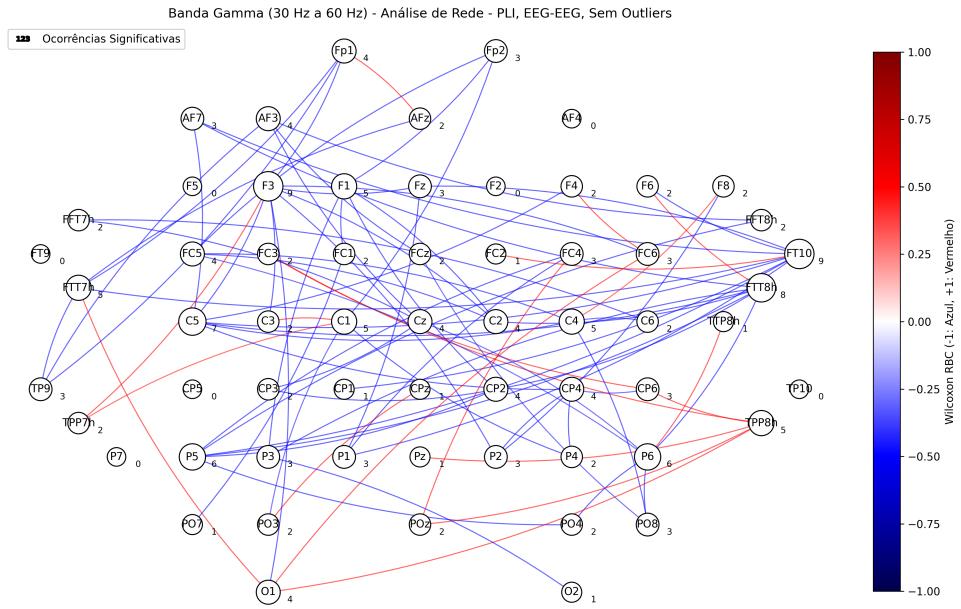


Figura 42 – Rede de conexões significativas na banda Gamma (30–60 Hz) para PLI (EEG-EEG) sem outliers. A rede é mais esparsa, mas destaca alguns pares de canais com conexões extremamente robustas.

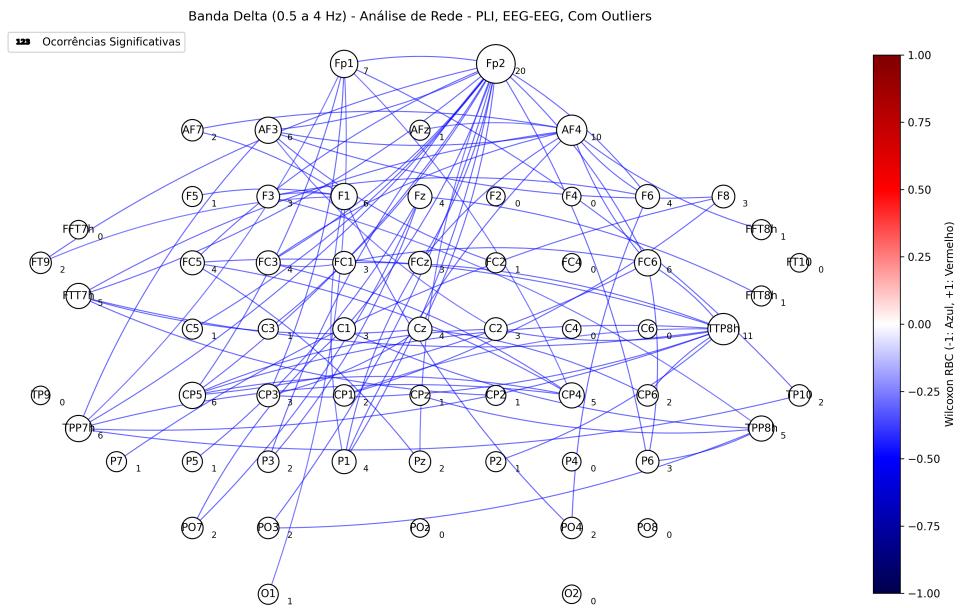


Figura 43 – Rede de conexões significativas na banda Delta (0.5–4 Hz) para PLI (EEG-EEG) com outliers mantidos. A estrutura é similar à observada sem outliers, com poucas conexões significativas.

(11 casos) em ambos os cenários, indicando que os efeitos cross-frequency identificados são altamente robustos e não dependem da presença de outliers.

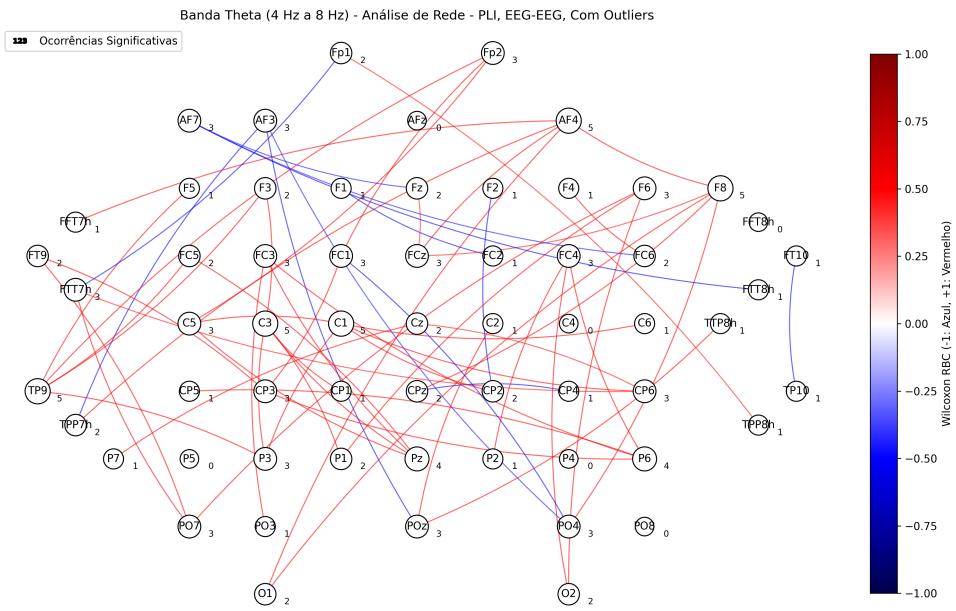


Figura 44 – Rede de conexões significativas na banda Theta (4–8 Hz) para PLI (EEG-EEG) com outliers mantidos. A conectividade moderada e os canais com alta centralidade se mantêm, confirmando a robustez dos efeitos.

8.6.1 Cenário Sem Outliers

8.6.1.1 Banda Delta (0.5–4 Hz)

8.6.1.2 Banda Theta (4–8 Hz)

8.6.1.3 Banda Alpha (8–13 Hz)

8.6.1.4 Banda Beta (13–30 Hz)

8.6.1.5 Banda Gamma (30–60 Hz)

8.6.2 Cenário Com Outliers

8.6.2.1 Banda Delta (0.5–4 Hz)

8.6.2.2 Banda Theta (4–8 Hz)

8.6.2.3 Banda Alpha (8–13 Hz)

8.6.2.4 Banda Beta (13–30 Hz)

8.6.2.5 Banda Gamma (30–60 Hz)

8.6.3 Comparação Geral entre Cenários para CF-PLM

Ao comparar os resultados dos cenários com e sem outliers para CF-PLM (EEG-ECG), observamos:

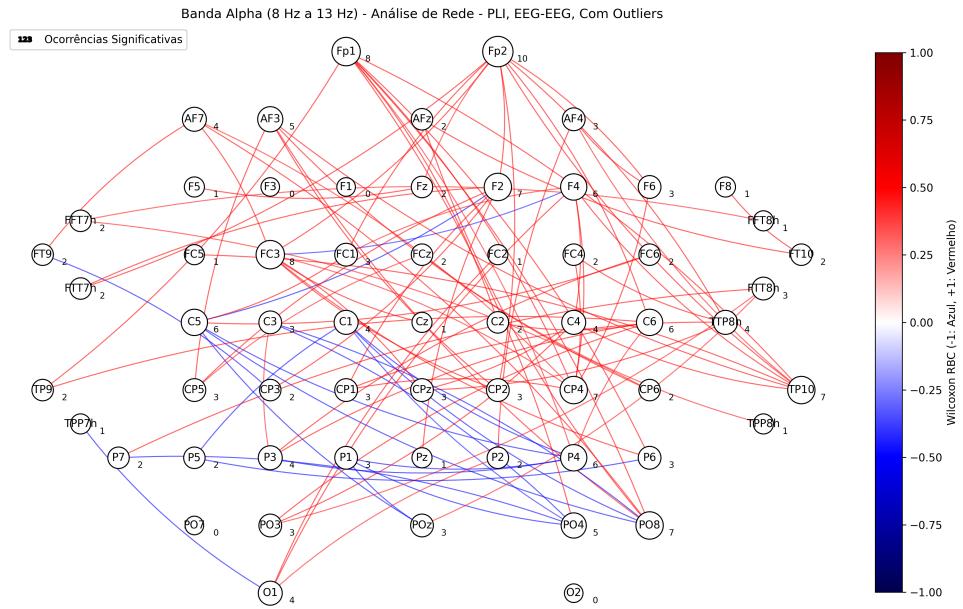


Figura 45 – Rede de conexões significativas na banda Alpha (8–13 Hz) para PLI (EEG-EEG) com outliers mantidos. A rede densa e o núcleo central de canais altamente conectados permanecem, demonstrando uma forte sincronização, similar à observada sem outliers.

- **Topologia Consistente:** A estrutura das redes – ou seja, quais canais se conectam e a contagem de conexões – é praticamente idêntica em ambos os cenários, para todas as bandas de frequência.
- **Número de Conexões Inalterado:** O número total de pares significativos (11 casos) permanece constante, evidenciando que os efeitos cross-frequency são robustos e não dependem da remoção de outliers.
- **Robustez dos Efeitos:** Todos os pares significativos exibem Wilcoxon RBC de +1, demonstrando que, independentemente da presença de outliers, os efeitos são extremamente fortes.

Essas análises confirmam a estabilidade e robustez dos efeitos cross-frequency medidos pelo CF-PLM para a interação entre EEG e ECG, fornecendo uma base sólida para investigações futuras sobre a integração dos sistemas neural e cardíaco.

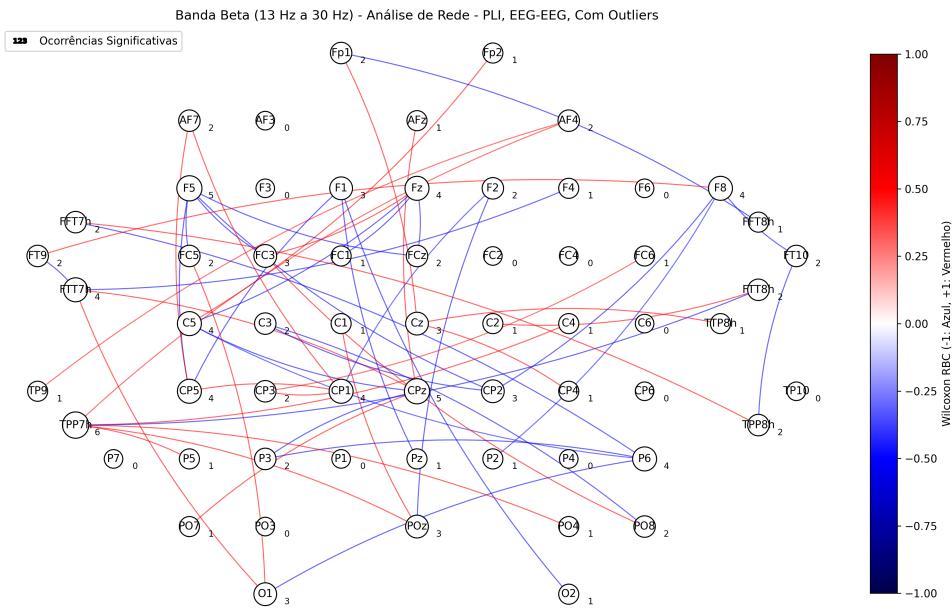


Figura 46 – Rede de conexões significativas na banda Beta (13–30 Hz) para PLI (EEG-EEG) com outliers mantidos. A distribuição das conexões é semelhante à observada no cenário sem outliers, evidenciando uma conectividade intermediária.

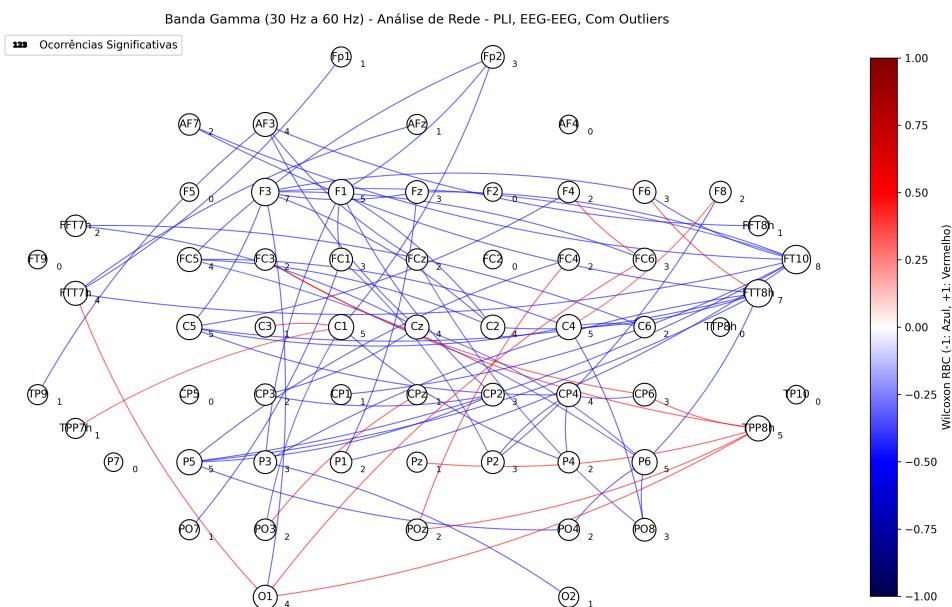


Figura 47 – Rede de conexões significativas na banda Gamma (30–60 Hz) para PLI (EEG-EEG) com outliers mantidos. Mesmo com a presença de outliers, a rede se mantém esparsa, destacando os pares de canais com conexões robustas.

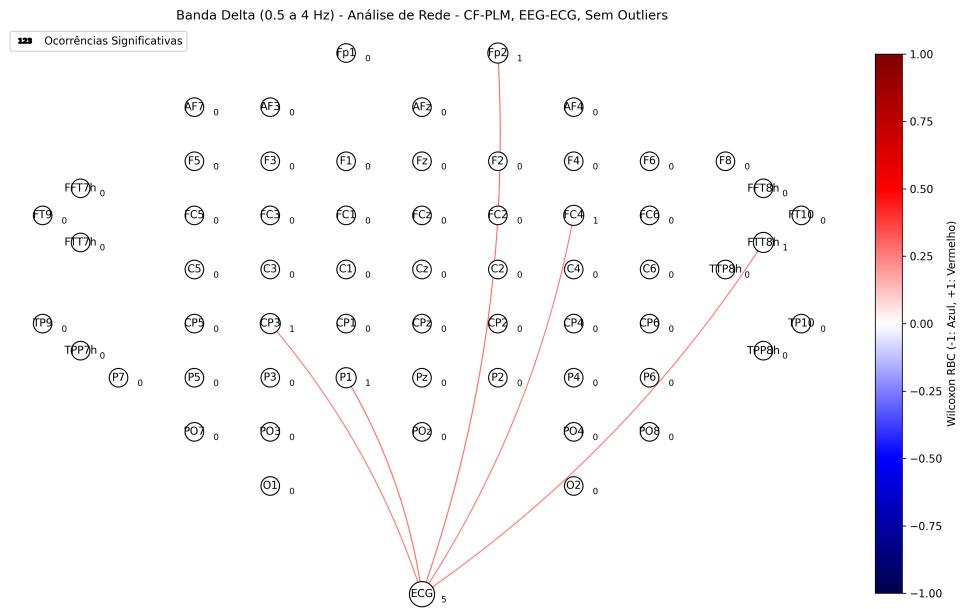


Figura 48 – Rede CF-PLM na banda Delta (0.5–4 Hz) para EEG-ECG sem outliers. A rede é bastante esparsa, indicando que a sincronização cross-frequency nesta faixa ocorre de forma pontual e em poucos pares de canais.

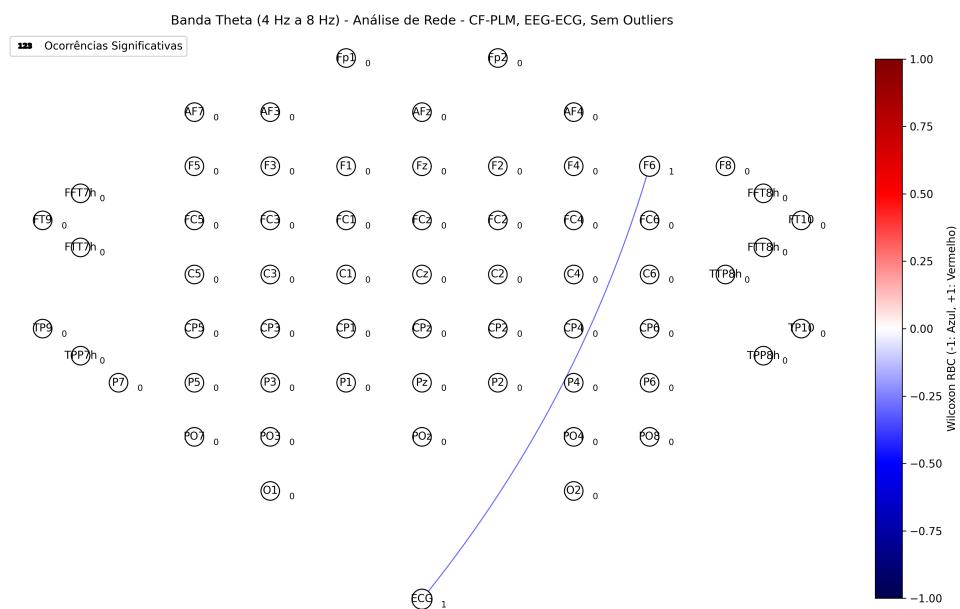


Figura 49 – Rede CF-PLM na banda Theta (4–8 Hz) para EEG-ECG sem outliers. A conectividade é moderada, com alguns canais apresentando maior número de conexões significativas, sugerindo que certos canais desempenham um papel crucial na integração cross-frequency nesta faixa.

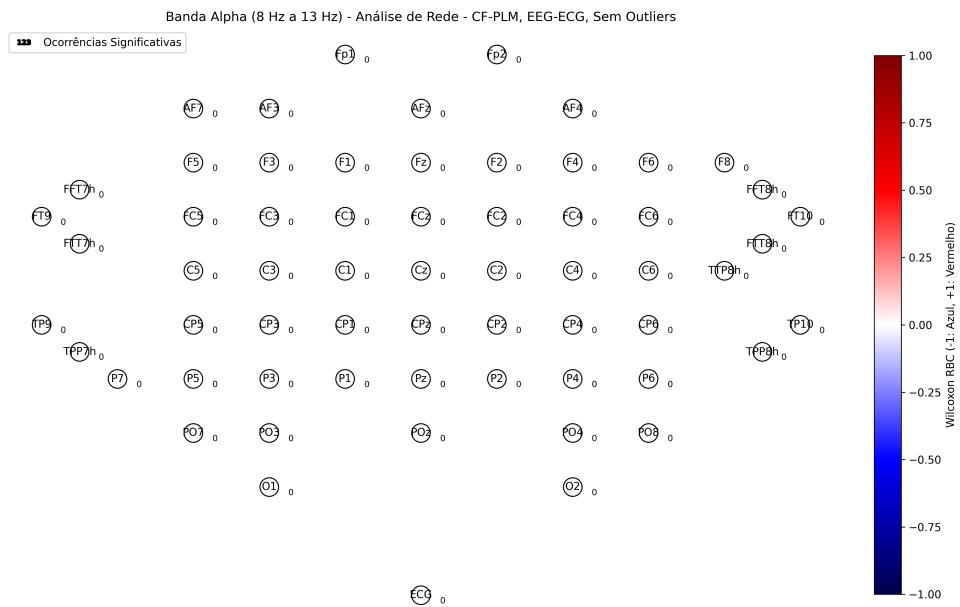


Figura 50 – Rede CF-PLM na banda Alpha (8–13 Hz) para EEG-ECG sem outliers. A rede apresenta conexões pontuais entre canais EEG e ECG, evidenciando a presença de sincronização cross-frequency específica nessa faixa.

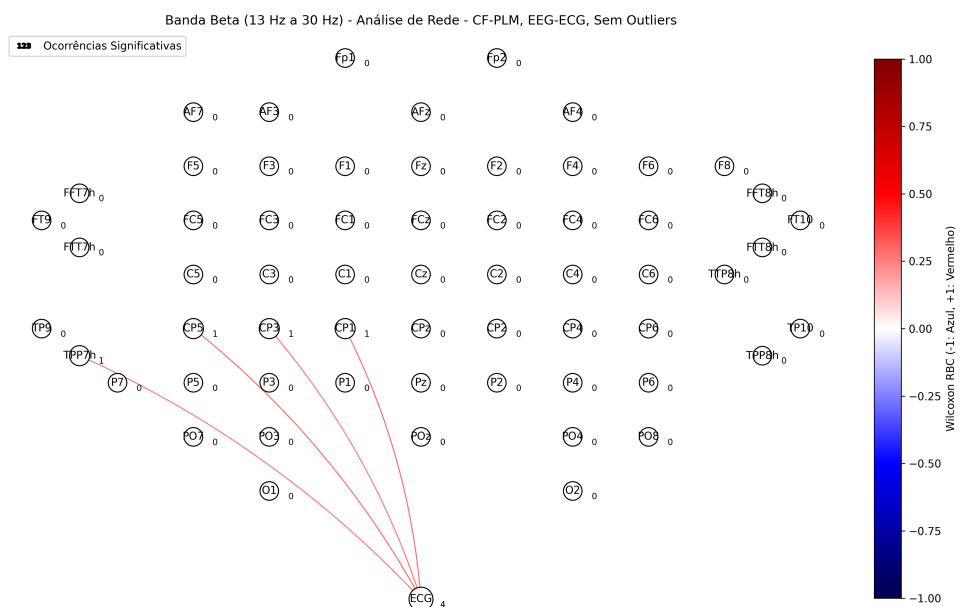


Figura 51 – Rede CF-PLM na banda Beta (13–30 Hz) para EEG-ECG sem outliers. Apesar da rede ser relativamente esparsa, os pares significativos indicam uma forte sincronização entre os canais, refletindo um efeito robusto nessa faixa.

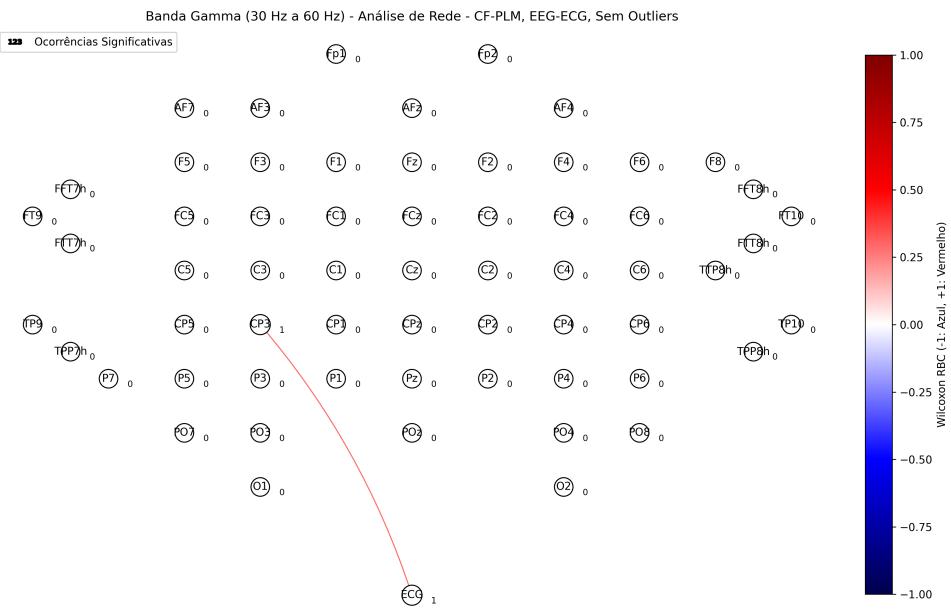


Figura 52 – Rede CF-PLM na banda Gamma (30–60 Hz) para EEG-ECG sem outliers. A rede destaca alguns pares com conexões extremamente robustas, embora a conectividade global seja pontual.

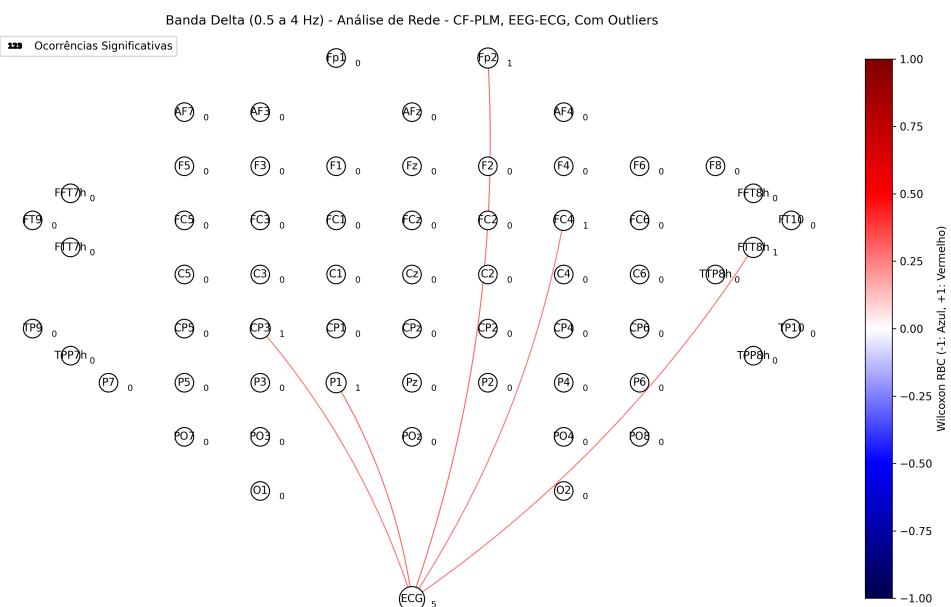


Figura 53 – Rede CF-PLM na banda Delta (0.5–4 Hz) para EEG-ECG com outliers. A estrutura da rede é idêntica à observada sem outliers, evidenciando a estabilidade dos efeitos cross-frequency nesta faixa.

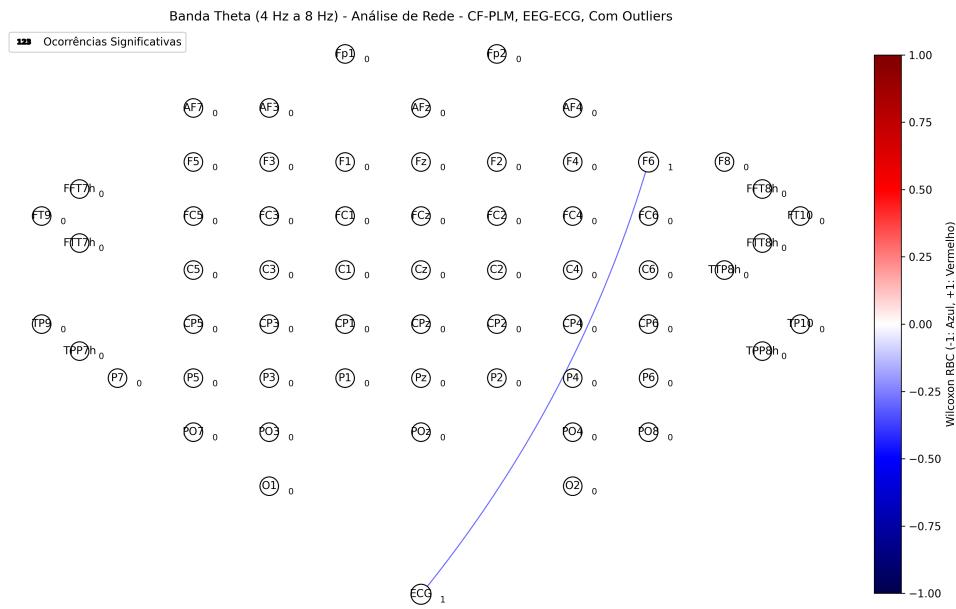


Figura 54 – Rede CF-PLM na banda Theta (4–8 Hz) para EEG-ECG com outliers. A conectividade e a distribuição dos nós permanecem semelhantes às observadas no cenário sem outliers.

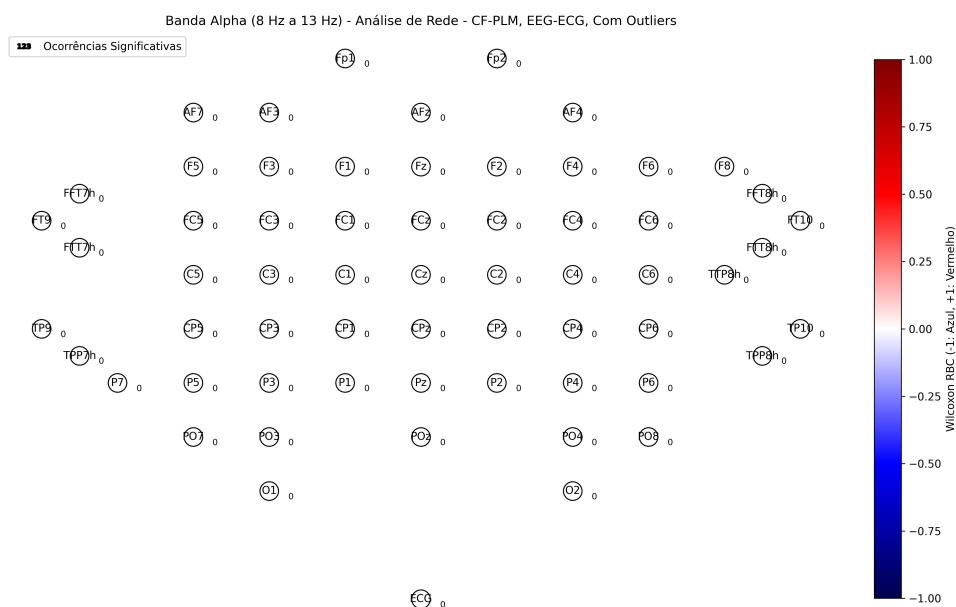


Figura 55 – Rede CF-PLM na banda Alpha (8–13 Hz) para EEG-ECG com outliers. A topologia da rede é idêntica à observada sem outliers, demonstrando que os efeitos robustos não são afetados pela presença de valores extremos.

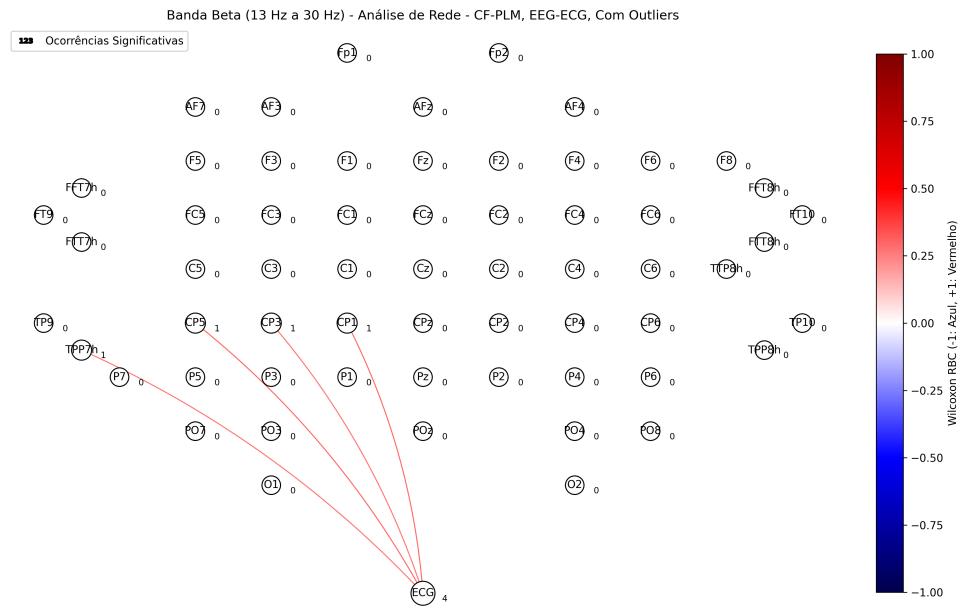


Figura 56 – Rede CF-PLM na banda Beta (13–30 Hz) para EEG-ECG com outliers. A rede apresenta uma conectividade robusta e a mesma topologia dos gráficos sem outliers, indicando que os valores extremos não alteram significativamente os efeitos identificados.

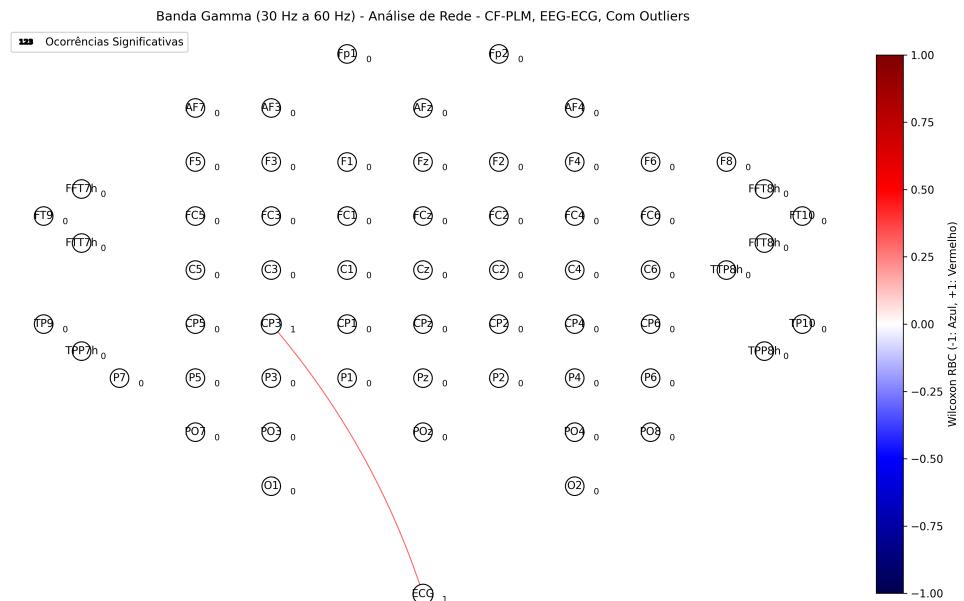


Figura 57 – Rede CF-PLM na banda Gamma (30–60 Hz) para EEG-ECG com outliers. A rede exibe os mesmos pares robustos de conexão (RBC = +1) observados sem outliers, confirmando a estabilidade dos efeitos cross-frequency na faixa de alta frequência.

Apêndices

APÊNDICE A – Primeiro Apêncice

Quisque facilisis auctor sapien. Pellentesque gravida hendrerit lectus. Mauris rutrum sodales sapien. Fusce hendrerit sem vel lorem. Integer pellentesque massa vel augue. Integer elit tortor, feugiat quis, sagittis et, ornare non, lacus. Vestibulum posuere pellentesque eros. Quisque venenatis ipsum dictum nulla. Aliquam quis quam non metus eleifend interdum. Nam eget sapien ac mauris malesuada adipiscing. Etiam eleifend neque sed quam. Nulla facilisi. Proin a ligula. Sed id dui eu nibh egestas tincidunt. Suspendisse arcu.

APÊNDICE B – Segundo apêndice com título tão grande quanto se queira porque ele já faz a quebra de linha da coisa toda

Maecenas dui. Aliquam volutpat auctor lorem. Cras placerat est vitae lectus. Curabitur massa lectus, rutrum euismod, dignissim ut, dapibus a, odio. Ut eros erat, vulputate ut, interdum non, porta eu, erat. Cras fermentum, felis in porta congue, velit leo facilisis odio, vitae consectetuer lorem quam vitae orci. Sed ultrices, pede eu placerat auctor, ante ligula rutrum tellus, vel posuere nibh lacus nec nibh. Maecenas laoreet dolor at enim. Donec molestie dolor nec metus. Vestibulum libero. Sed quis erat. Sed tristique. Duis pede leo, fermentum quis, consectetuer eget, vulputate sit amet, erat.

Donec vitae velit. Suspendisse porta fermentum mauris. Ut vel nunc non mauris pharetra varius. Duis consequat libero quis urna. Maecenas at ante. Vivamus varius, wisi sed egestas tristique, odio wisi luctus nulla, lobortis dictum dolor ligula in lacus. Vivamus aliquam, urna sed interdum porttitor, metus orci interdum odio, sit amet euismod lectus felis et leo. Praesent ac wisi. Nam suscipit vestibulum sem. Praesent eu ipsum vitae pede cursus venenatis. Duis sed odio. Vestibulum eleifend. Nulla ut massa. Proin rutrum mattis sapien. Curabitur dictum gravida ante.

Phasellus placerat vulputate quam. Maecenas at tellus. Pellentesque neque diam, dignissim ac, venenatis vitae, consequat ut, lacus. Nam nibh. Vestibulum fringilla arcu mollis arcu. Sed et turpis. Donec sem tellus, volutpat et, varius eu, commodo sed, lectus. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Quisque enim arcu, suscipit nec, tempus at, imperdiet vel, metus. Morbi volutpat purus at erat. Donec dignissim, sem id semper tempus, nibh massa eleifend turpis, sed pellentesque wisi purus sed libero. Nullam lobortis tortor vel risus. Pellentesque consequat nulla eu tellus. Donec velit. Aliquam fermentum, wisi ac rhoncus iaculis, tellus nunc malesuada orci, quis volutpat dui magna id mi. Nunc vel ante. Duis vitae lacus. Cras nec ipsum.

Anexos

ANEXO A – Nome do Primeiro Anexo

Sed mattis, erat sit amet gravida malesuada, elit augue egestas diam, tempus scelerisque nunc nisl vitae libero. Sed consequat feugiat massa. Nunc porta, eros in eleifend varius, erat leo rutrum dui, non convallis lectus orci ut nibh. Sed lorem massa, nonummy quis, egestas id, condimentum at, nisl. Maecenas at nibh. Aliquam et augue at nunc pellentesque ullamcorper. Duis nisl nibh, laoreet suscipit, convallis ut, rutrum id, enim. Phasellus odio. Nulla nulla elit, molestie non, scelerisque at, vestibulum eu, nulla. Ut odio nisl, facilisis id, mollis et, scelerisque nec, enim. Aenean sem leo, pellentesque sit amet, scelerisque sit amet, vehicula pellentesque, sapien.

ANEXO B – Nome de Outro Anexo

Phasellus id magna. Duis malesuada interdum arcu. Integer metus. Morbi pulvinar pellentesque mi. Suspendisse sed est eu magna molestie egestas. Quisque mi lorem, pulvinar eget, egestas quis, luctus at, ante. Proin auctor vehicula purus. Fusce ac nisl aliquam ante hendrerit pellentesque. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Morbi wisi. Etiam arcu mauris, facilisis sed, eleifend non, nonummy ut, pede. Cras ut lacus tempor metus mollis placerat. Vivamus eu tortor vel metus interdum malesuada.